Data Science, Machine Learning, Deep Learning

Jour 1 : toute la théorie, des prérequis aux données temporelles. Les termes techniques restent en anglais, parce que c'est en anglais que vous les retrouverez partout ailleurs.

Parcours IAS · aucun notebook ne sera ouvert aujourd'hui

JOUR 1 · THEORIE S0 A S4

Le déroulé de la journée

0:00	**Accueil et fil rouge**	ce que l'on construit, et la question qui revient partout
0:20	**A. Fondamentaux**	data et information, vocabulaire, ce que l'IA n'est pas
1:40	Pause	15 minutes
1:55	**B. Cadrer un problème**	une demande n'est pas un problème
3:15	Déjeuner	une heure et 30 minutes
3:15	**C. Supervised learning**	le chiffre qui ment, et le seuil qui coûte
5:02	Pause	15 minutes
5:17	**D. Neural networks**	un neurone est une somme pondérée
6:37	**E. Données temporelles**	ce qui casse quand les lignes ont un ordre
7:27	**F. Unsupervised learning**	les mêmes données, sans la colonne à prédire

Les trois journées

24 heures, et le défi final est distribué à la fin du jour 3.

Jour	Contenu	Forme
Aujourd'hui	toute la théorie, de S0 à S4, et S7	diaporama, sans code
Jour 2	TD sur S0 à S4, et S7	notebooks, en binôme, en autonomie
Jour 3	S5 et S6	4 h de théorie puis 4 h de TD

Une agence de santé environnementale surveille la pollution de l'air. L'analyseur certifié coûte cher. Les capteurs bon marché, non.

La question qui tient toute la journée, et toute la formation : est-ce que les capteurs bon marché peuvent dire ce que l'analyseur certifié aurait dit ? Les données sont celles d'une vraie station de mesure, sur une année entière.

JOUR 1 · THEORIE S0 A S4

Ce que cette journée vous donne, et ce qu'elle ne donne pas

Elle donne le vocabulaire, les idées, et surtout la capacité de dire si un résultat que l'on vous présente est crédible ou non.

Elle ne donne pas la pratique. Taper du code s'apprend en tapant du code, et c'est demain.

Le piège du jour tout paraîtra simple. C'est normal : voir quelqu'un faire est toujours simple. La difficulté arrive demain.

Ce qu'il faut noter pas les définitions, elles sont dans les notebooks. Notez les questions que vous vous posez et qui restent sans réponse.

A

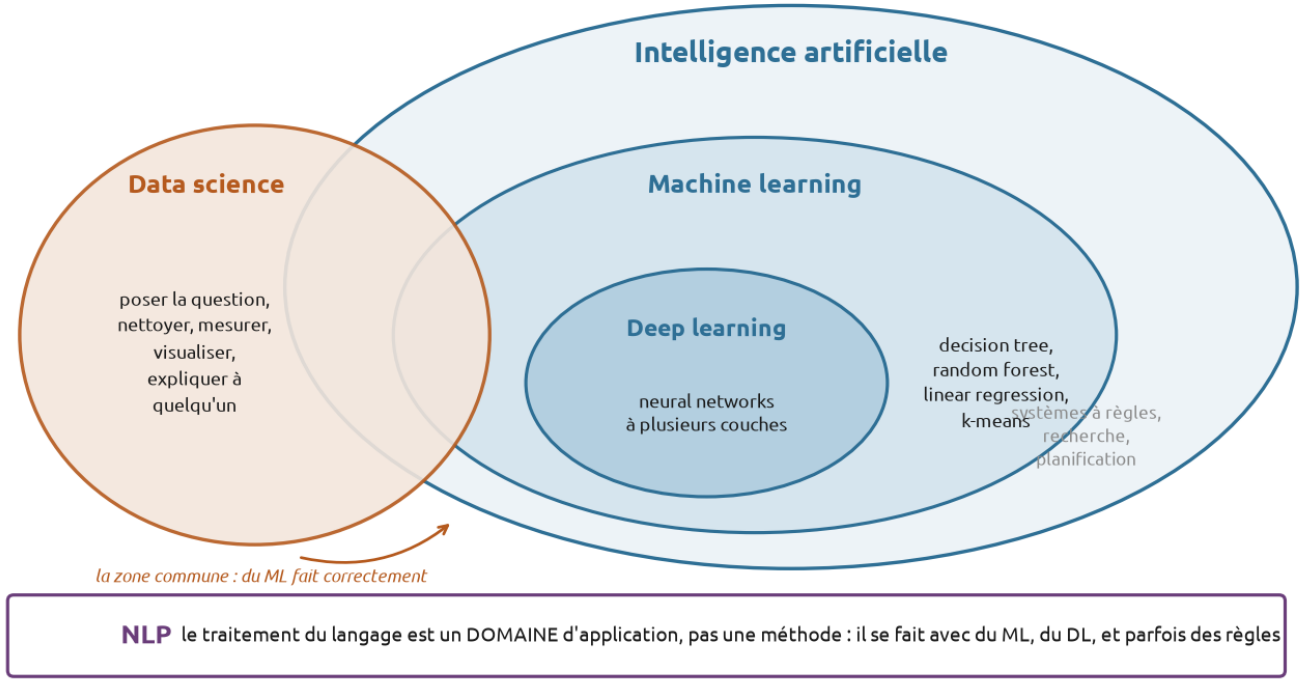
Fondamentaux et vocabulaire

Data et information ne sont pas la même chose. Un modèle n'est pas une intelligence. Les mots que vous entendrez en entreprise, et ce qu'ils désignent vraiment.

Quatre mots que l'on vous dira d'employer, et qui ne designent pas la même chose.

Data science, machine learning, deep learning, NLP. Ils ne sont ni synonymes ni interchangeables, et confondre les deux premiers est la source de la plupart des projets qui échouent avant d'avoir commence.

Les quatre mots, et comment ils se rangent



Trois ensembles emboîtés et une pratique qui les recoupe. L'intelligence artificielle contient le machine learning, qui contient le deep learning. La data science n'est pas dans cette pile : c'est un métier, qui utilisé le ML entre autres choses. Et le NLP est un domaine d'application, pas une méthode.

JOUR 1 · THEORIE S0 A S4

Data science : le métier, et ce qu'il contient vraiment

Le machine learning est une étape sur cinq, et ce n'est pas la plus longue.

Poser la question transformer une demande en problème traitable. C'est le bloc B, et c'est la ou l'on gagne ou perd un projet.

Obtenir et nettoyer la part la plus longue, et de loin. Les deux journées de TD y passeront un temps considérable.

Modeliser la part visible, la plus courte, et celle que les cours gonflent.

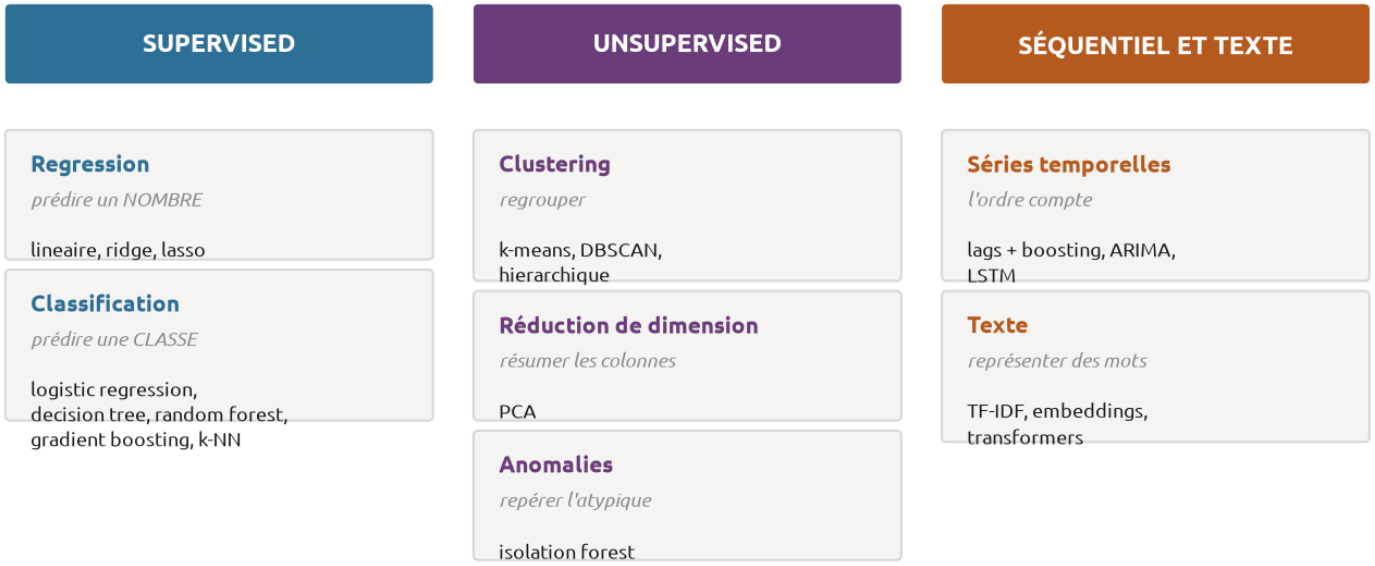
Mesurer honnêtement choisir la métrique avant de voir les résultats, et la traduire en euros ou en patients.

Expliquer a quelqu'un un résultat que personne ne comprend ne change aucune décision, donc il ne sert a rien.

Un modèle, c'est trois choses : une forme, un objectif, et une façon de s'ameliorer.

Une FORME : une droite, un decision tree, un neural network. Un OBJECTIF : un minimiser, qui dit ce que « se tromper » veut dire. Et une PROCEDURE qui ajuste la forme pour faire baisser ce nombre. Tout le reste de la formation ne change que la forme.

La carte des familles, et la question à laquelle chacune répond



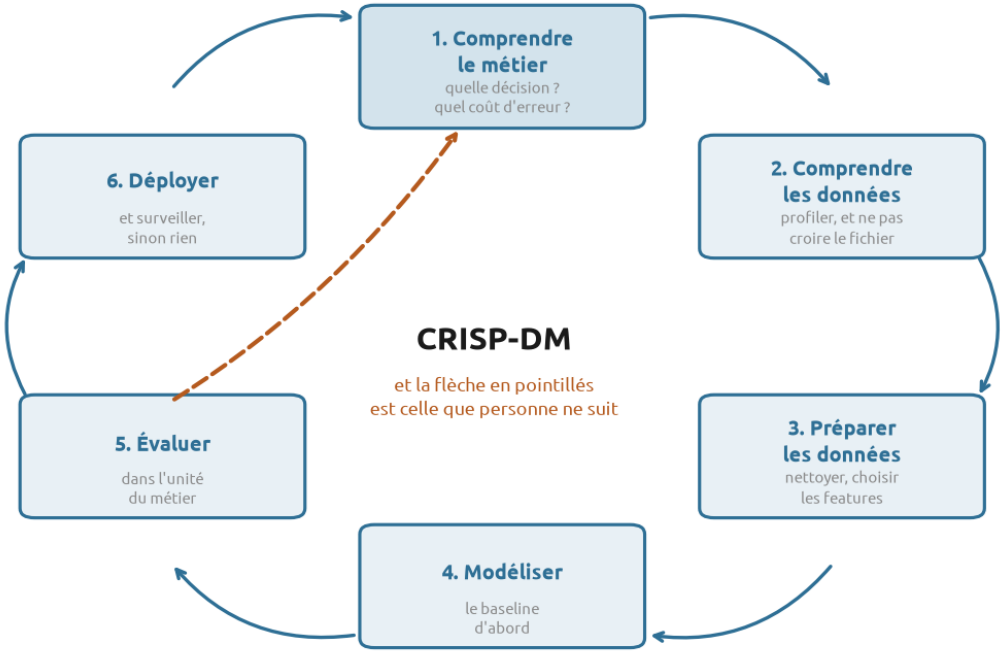
Chaque famille répond à une QUESTION différente. Le choix du modèle vient après celui de la question.

On ne choisit pas un modèle, on choisit d'abord une question. Le nom de l'algorithme vient en dernier, et c'est la décision la moins importante des trois journées.

Et une méthode pour organiser tout cela : CRISP-DM.

Six phases, un cycle, et quarante ans d'usage industriel. Ce n'est pas une norme a réciter : c'est la carte qui dit ou vous êtes et ce que vous avez sauté.

CRISP-DM, et la fleche que personne ne suit



Le cycle se lit dans le sens des aiguilles. La fleche en pointillés, qui ramène de l'évaluation a la compréhension du métier, est celle que tout le monde dessine et que presque personne ne parcourt : elle signifie accepter que la question de départ etait mal posée.

Ce que chaque phase vous demande, concrètement

1. Comprendre le métier quelle décision ce chiffre alimente-t-il, et que coûte une erreur dans chaque sens ?

2. Comprendre les données profiler, et ne pas croire le fichier. Vous le ferez demain sur un fichier qui ment.

3. Preparer les données nettoyer, choisir les features, et vérifier qu'elles existeront au moment de la prédiction.

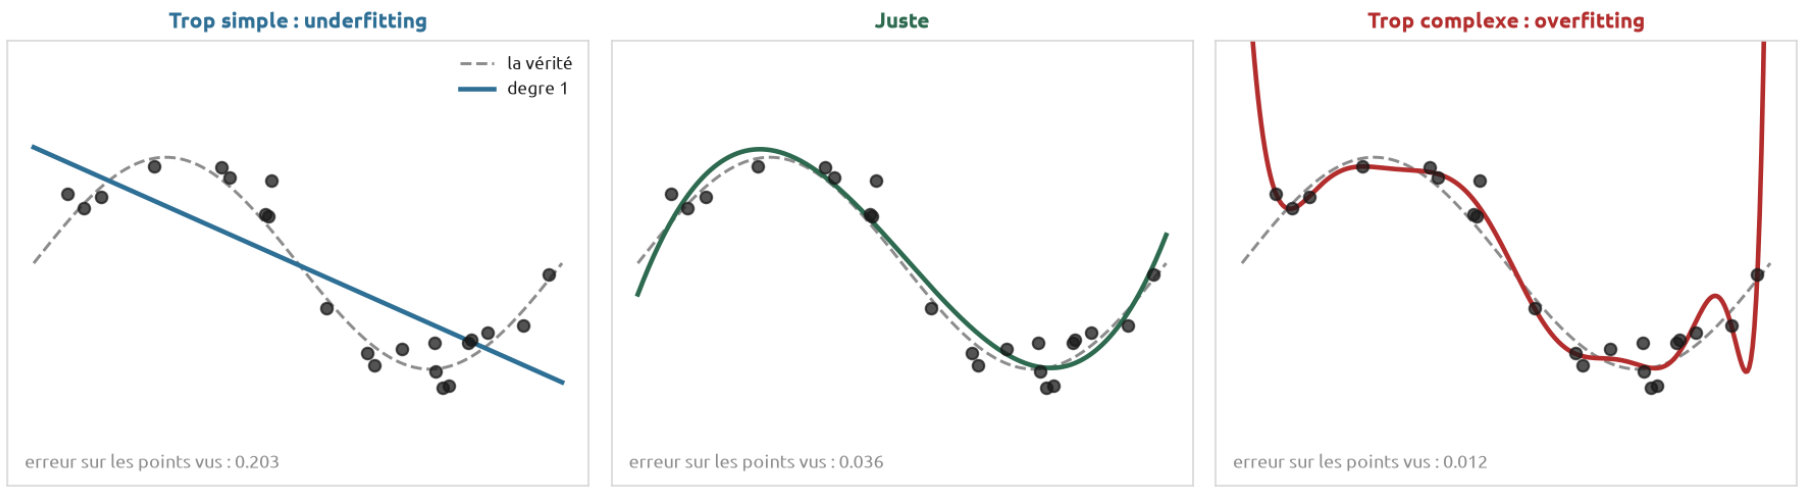
4. Modeliser le baseline d'abord, toujours. Le modèle ensuite, et c'est souvent trois lignes.

5. Evaluer dans l'unité du métier, avec une métrique choisie AVANT de voir les résultats.

6. Deployer et surveiller un modèle qui tourne sans surveillance ne tombe pas en panne : il devient faux en silence.

Et le piège qui attend a la phase 4

Le modèle de droite a la plus petite erreur sur les points qu'il a vus, et c'est le pire des trois.



Les mêmes points, trois modèles. Celui de droite passe exactement par chaque point et a donc la plus petite erreur sur ce qu'il a vu. C'est le pire des trois, et il faut des données qu'il n'a jamais vues pour s'en apercevoir.

Une donnée devient une information quand elle répond à une question que quelqu'un se posait déjà.

C'est la distinction la plus utile de la journée, et la plus souvent escamotée. Tant que personne n'a posé de question, accumuler des données ne produit rien.

La même mesure, trois statuts différents

Ce qui change d'une ligne à l'autre n'est pas la précision, c'est la question posée.

7,2 une donnée. Un nombre, sans unité, sans contexte. Inutilisable.

7,2 mg/m3 de CO, station de mesure, mardi 14 h toujours une donnée, mais complète. On sait ce que c'est.

Le seuil réglementaire est à 10 mg/m3, nous sommes à 7,2 une information. Quelqu'un se demandait si le seuil était dépassé.

Depuis trois mois, les dépassements arrivent toujours un mardi de la connaissance. Un schéma, pas un relevé, et cela change une décision.

Le vocabulaire minimal, et il est en anglais

Ces six mots suffisent pour les trois jours. Le reste se déduit.

Terme	Ce que c'est	Dans notre fil rouge
sample	une ligne, une observation	une heure de mesuré à la station
feature	une colonne d'entrée	la réponse d'un capteur bon marché
target	la colonne à prédire	la mesuré de l'analyseur certifié
model	la fonction apprise des exemples	capteurs vers mesuré certifiée
training set	les exemples pour apprendre	les heures que le modèle voit
test set	les exemples gardés de côté	celles qu'il ne voit jamais

Trois familles, et ce qui les sépare

	Supervised	Unsupervised	Reinforcement
Données	X et une target y	X seulement	un environnement
Question	prédire y	quelle structure dans X ?	quelle action ?
Exemples	classification, regression	clustering, anomaly detection	robotique, jeux
Au programme	oui, jours 1 à 3	oui, jour 3	non, cité pour mémoire

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

L'intelligence artificielle, c'est le deep learning.

LA MESURE DIT

Sur des données en tableau, qui sont la majorité des données industrielles et hospitalières, un random forest fait aussi bien ou mieux qu'un neural network, sans scaling, sans learning rate et sans architecture à choisir. Le bloc D le mesurera devant vous.

LA BONNE VERSION

Le deep learning gagne quand les features doivent être découvertes au lieu d'être mesurées : des pixels, du son, du texte. Si vous pouvez écrire les colonnes utiles, commencez par un decision tree.

Les mots que vous entendrez, et ce qu'ils désignent

big data un volume tel que les outils habituels ne suffisent plus. Presque aucun projet de santé publique n'est dans ce cas.

data mining chercher des schémas sans hypothèse de départ. Ancien nom, largement remplacé par machine learning.

IA générative, LLM des modèles qui produisent du texte ou des images. Le jour 3 en construit un système complet, et le casse.

MLOps tout ce qui fait qu'un modèle tourne encore dans six mois. Le vrai métier, et la partie que les cours sautent.

algorithme une suite d'instructions. Le mot ne dit rien sur la qualité de ce qu'il produit, contrairement à ce que la presse en fait.

En programmation classique, vous écrivez les règles. En machine learning, vous fournissez des exemples et les règles sont déduites.

C'est toute la différence, et elle a une conséquence immédiate : si vos exemples sont biaisés, vos règles le seront, et aucune relecture de code ne le montrera.

Les quatre questions, et vous les poserez partout

La carte que chaque séance remplit, et qui résume la formation entière.

1. Quelle est la target ? que prédit-on exactement, dans quelle unité, et pour quelle décision ?

2. Quel est le baseline ? que donne la solution la plus bête ? Sans cela, aucun score ne veut dire quoi que ce soit.

3. Comment mesure-t-on ? sur quelles données, avec quelle métrique, et choisie avant de voir les résultats.

4. Qu'est-ce qui peut fuir ? quelle information le modèle a-t-il reçue qu'il n'aura pas le jour de la mise en service ?

B

Cadrer un problème, et le charger

Une demande n'est pas un problème. Un fichier n'est pas des données. Et le meilleur score du tableau est souvent celui qu'il faut refuser.

« Est-ce qu'on peut arrêter de payer l'analyseur certifié ? »

Voilà la demande, telle qu'elle arrive. Elle est parfaitement claire pour celui qui la pose, et elle n'est pas encore un problème que l'on puisse traiter.

Les cinq éléments d'une spécification

	L'élément	Pour notre demande
1	la target : ce que l'on prédit	la mesure de CO de l'analyseur certifié
2	l'unit of analysis : la maille	une heure de mesure à la station
3	les inputs disponibles	les capteurs bon marché, et eux seuls
4	la metric : comment on mesure	l'erreur en mg/m3, dans l'unité du métier
5	good enough : le seuil de décision	la question difficile, et elle ne nous appartient pas

Trois demandes réelles, et ce qu'il faut en faire

Le TD de demain vous en fera cadrer trois de ce genre, par écrit.

« Nos capteurs dérivent, on peut savoir quand les recalibrer ? » target floue. Il faut demander quelle dérive compte comme une dérive, et vérifier qu'il existe des exemples de dérive annotés. Il n'y en a souvent aucun.

« Les émissions semblent pires certains jours, pourquoi ? » ce n'est pas un problème de prédiction. On demande une explication, pas une prévision, et les deux ne se traitent pas pareil.

« Peut-on arrêter de payer l'analyseur certifié ? » celle-là se cadre : target, maille, metric. Mais le seuil d'acceptabilité est une question de conformité avant d'être une question technique.

Charger le fichier. Cela va mal se passer.

```
station = pd.read_csv('data/station_raw.csv')

# -> une seule colonne, et des nombres devenus du texte
```

Le fichier est européen : séparateur point-virgule et virgule décimale. Chargé naïvement, pandas produit un tableau d'une seule colonne, et toutes les mesures deviennent des chaînes de caractères.

La version qui marche, et le réflexe qui va avec

```
station = pd.read_csv('data/station_raw.csv', sep=';', decimal=',')

station.dtypes          # AVANT describe(), toujours
station.shape
station.isna().mean()
```

Vérifier les dtypes avant toute statistique. Si une colonne est arrivée en texte, describe() la saute en silence et vous ne le saurez jamais.

Ce que le fichier contient vraiment

9 357 x 15

Et deux colonnes entièrement vides, plus 114 lignes entièrement vides.

Les deux colonnes sans nom viennent des point-virgules en fin de ligne. Les 114 lignes vides sont la queue du fichier. Un `.shape` que l'on n'a pas interrogé n'est pas une information, c'est un nombre.

Ce que l'on croit, ce que la mesure dit

ON CROIT

Il n'y a aucune valeur manquante dans ce fichier.

LA MESURE DIT

`isna().sum()` renvoie zéro partout. Et pourtant la ligne `min` de `describe()` affiche exactement -200,00 pour chaque colonne de mesure.

LA BONNE VERSION

-200 est un sentinel : la façon dont cet instrument code « pas de mesure ». Tant qu'on ne l'a pas remplacé par un vrai marqueur de valeur manquante, toutes les moyennes sont fausses et aucune alerte ne le dira.

Lire une distribution, sans formule

La moyenne le centre, et elle se déplace dès qu'une valeur extrême apparaît.

La médiane la valeur du milieu. Elle ne bouge pas quand une valeur extrême apparaît, ce qui est souvent ce que l'on veut.

L'écart-type la distance typique à la moyenne. Il répond à « à quel point c'est étalé », ce que « la moyenne est de 2,1 » ne dit pas.

Les quantiles ils coupent les données en quarts. `describe()` les donne gratuitement et presque personne ne les lit.

La règle si moyenne et médiane s'écartent franchement, la distribution est asymétrique, et une moyenne seule devient trompeuse.

La corrélation, et ce qu'elle n'est pas

Ce qu'elle mesure à quel point deux colonnes montent et descendent ensemble, et rien d'autre.

Ce qu'elle ne mesure pas la causalité, et aucune relation qui ne soit pas une droite. Deux colonnes liées par une courbe peuvent afficher une corrélation proche de zéro.

Pourquoi elle compte ici une corrélation très forte entre deux colonnes a trois explications possibles, et il faut les distinguer avant de modéliser.

Les trois explications de la physique, une formule de tableur, ou une fuite. Seule la question « par quel mécanisme ? » les sépare.

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

Cette colonne est très corrélée à la target, donc elle est utile.

LA MESURE DIT

Dans ce fichier, la colonne d'humidité absolue AH se reconstruit à partir de la température T et de l'humidité relative RH avec un R2 de **0,88**. Ce n'est pas une découverte sur l'air : c'est une formule de thermodynamique appliquée par celui qui a préparé le fichier.

LA BONNE VERSION

Une colonne dérivée n'apporte aucune information nouvelle. Elle donne au modèle l'air d'avoir trouvé une relation alors qu'il a trouvé votre tableur.

Les canaux de l'analyseur certifié sont, eux aussi, dans le fichier.

Les y laisser donne un modèle meilleur. Et parfaitement inutilisable, puisque le projet consiste précisément à se passer de cet instrument.

Trois modèles, et le meilleur est à refuser

Mesuré sur les données du TD de vendredi, et reproductible.

Modèle	MAE	Déployable ?
baseline : prédire toujours la moyenne	1,107	oui, et sans intérêt
capteurs bon marché seuls	0,308	oui, c'est le projet
avec les canaux de l'analyseur certifié	0,259	non, jamais

Le meilleur score du tableau est celui qu'il faut jeter

16 %

C'est l'avance du modèle que l'on ne pourra jamais mettre en service.

Rien n'est cassé. Pas de bug, pas de données de test touchées, pas de mélange. Le modèle utilise simplement un instrument que le projet veut supprimer.

Pour chaque colonne : au moment où je dois produire cette prédiction, ce nombre existera-t-il vraiment ?

C'est le seul test qui attrape ce genre de fuite. Il n'est pas statistique, il est opérationnel, et il se pose colonne par colonne avant de modéliser.

Ce que le bloc B a établi, et qui ne changera plus

Une demande n'est pas un problème target, maille, inputs, metric, seuil. Cinq éléments, et le cinquième se demande.

Un fichier n'est pas des données dtypes avant describe, et lire la ligne min avant de croire isna().

Une corrélation forte a trois causes de la physique, une formule, ou une fuite.

Le baseline d'abord 1,107 ici. Sans lui, 0,308 ne veut rien dire.

Le meilleur score peut être le mauvais et seule la question opérationnelle le montre.

C

Supervised learning, et le chiffre qui ment

On garde exactement les réflexes du bloc B et on change seulement la nature de la target : au lieu d'un nombre à prédire, une décision à prendre.

Un patient sort de l'hôpital. Reviendra-t-il sous 30 jours ?

101 766 séjours hospitaliers réels, 50 colonnes, en open data. La réadmission précoce coûte cher au système de santé et signale souvent une sortie organisée trop vite. La question est donc posée partout, et elle est difficile.

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

Il suffit de prédire qui sera réadmis.

LA MESURE DIT

Dans ce fichier, 1 652 séjours se terminent par un décès et 771 par des soins palliatifs. Ces patients ne seront jamais réadmis, et un modèle qui les garde apprend que « décédé » prédit « pas de réadmission ».

LA BONNE VERSION

C'est vrai, inutile et dangereux. Il faut retirer ces lignes, et c'est une faute de définition de la target, pas une faute de code. Aucun test ne l'attrape. Après nettoyage, 99 343 séjours restent.

Le taux de base, et il décide de tout ce qui suit

11,39 %

C'est la part des séjours suivis d'une réadmission sous 30 jours.

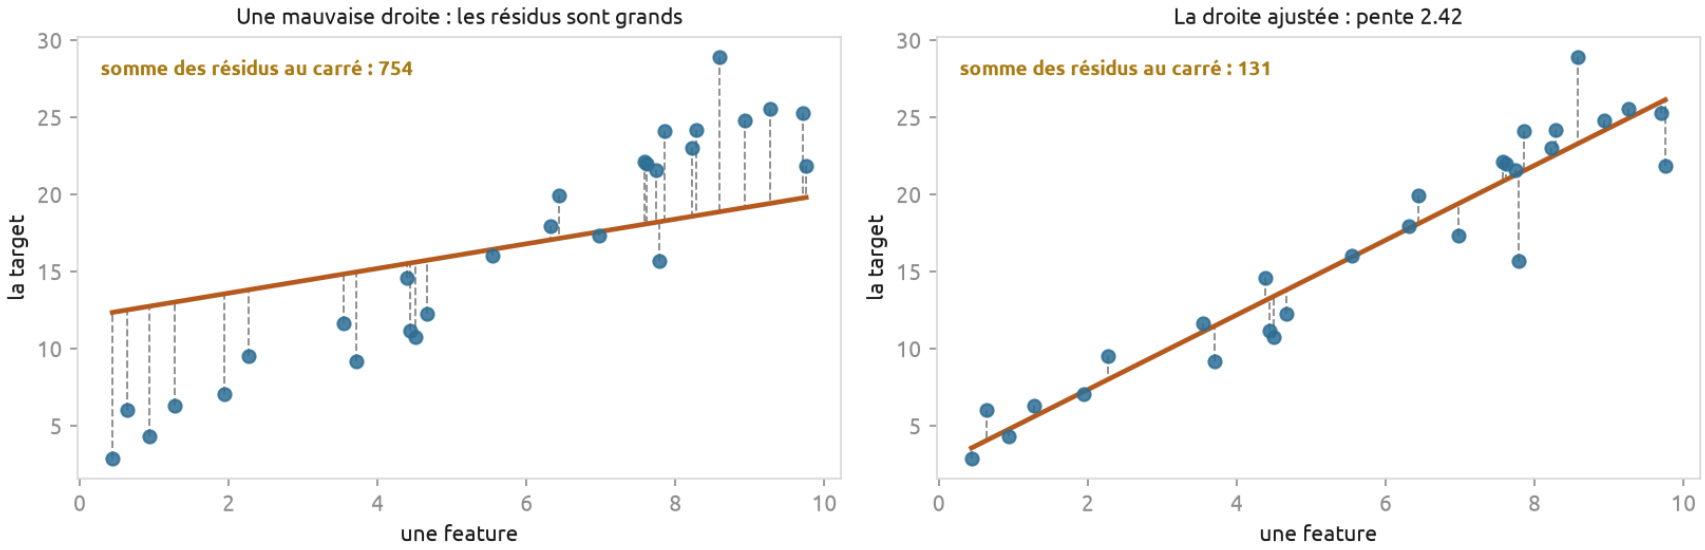
Donc un modèle qui répond systématiquement « non » obtient **88,61 %** d'accuracy. Avant de construire quoi que ce soit, c'est le chiffre à battre, et c'est celui que personne n'annonce dans les présentations.

Avant les metriques : comment ces modèles fonctionnent-ils, au juste ?

Quatre familles, quatre façons de tracer une frontière. Les figures qui suivent ne sont pas des illustrations : chacune a ete obtenue en exécutant l'algorithme et en traçant ce qu'il a fait.

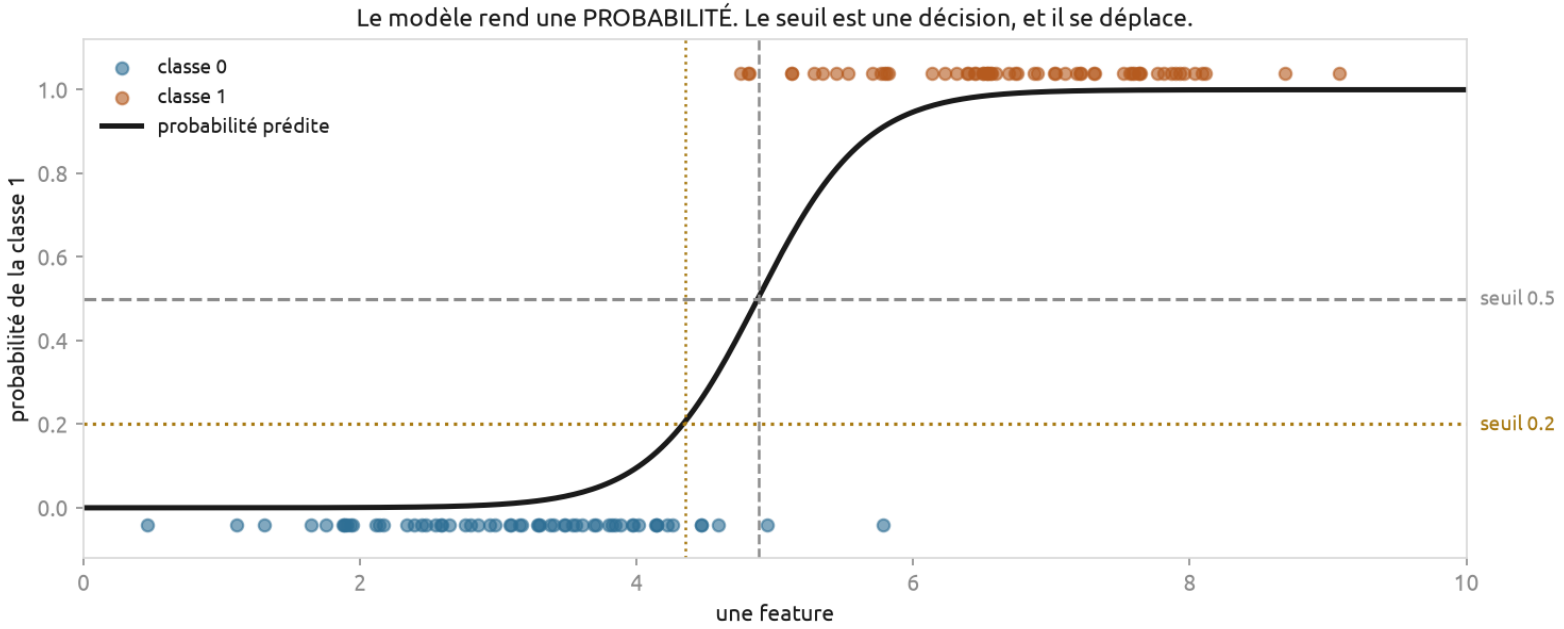
Linear regression : ajuster veut dire minimiser

« Ajuster » veut dire : choisir la droite qui minimise les traits pointilles



A gauche une mauvaise droite, a droite la droite ajustée. Les traits pointillés sont les écarts entre ce que le modèle prédit et la vérité. « Ajuster » ne veut rien dire de plus que : choisir la droite qui rend la somme de ces écarts au carré la plus petite possible.

Logistic regression : une probabilité, puis une décision

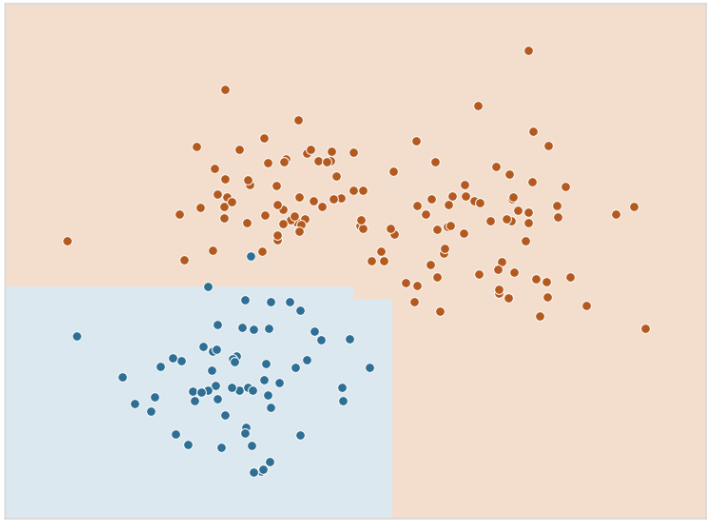


Le modèle ne rend pas une classe, il rend une PROBABILITE, et c'est la courbe noire. Le seuil la transforme en décision, et il se déplace : la ligne grise a 0,50 et la ligne dorée a 0,20 donnent deux systèmes différents a partir du même modèle.

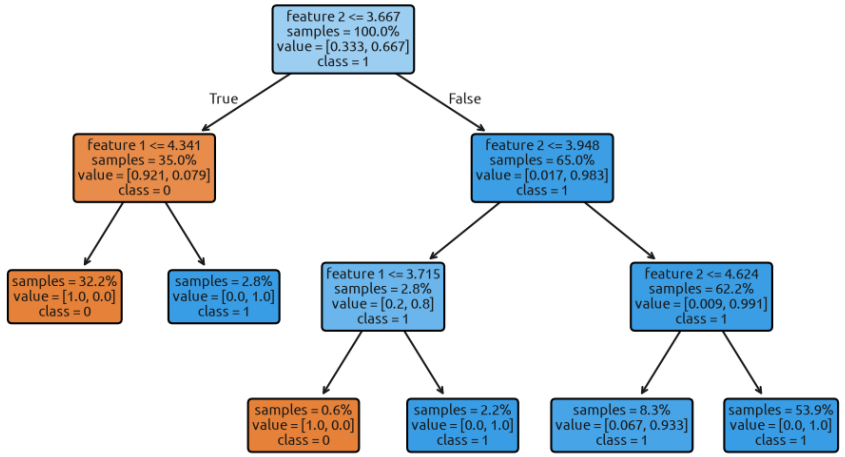
Decision tree : une suite de questions

Chaque noeud est une question « cette feature dépasse-t-elle ce seuil ? ». Les frontières sont donc toujours des angles droits.

L'espace, découpé en rectangles



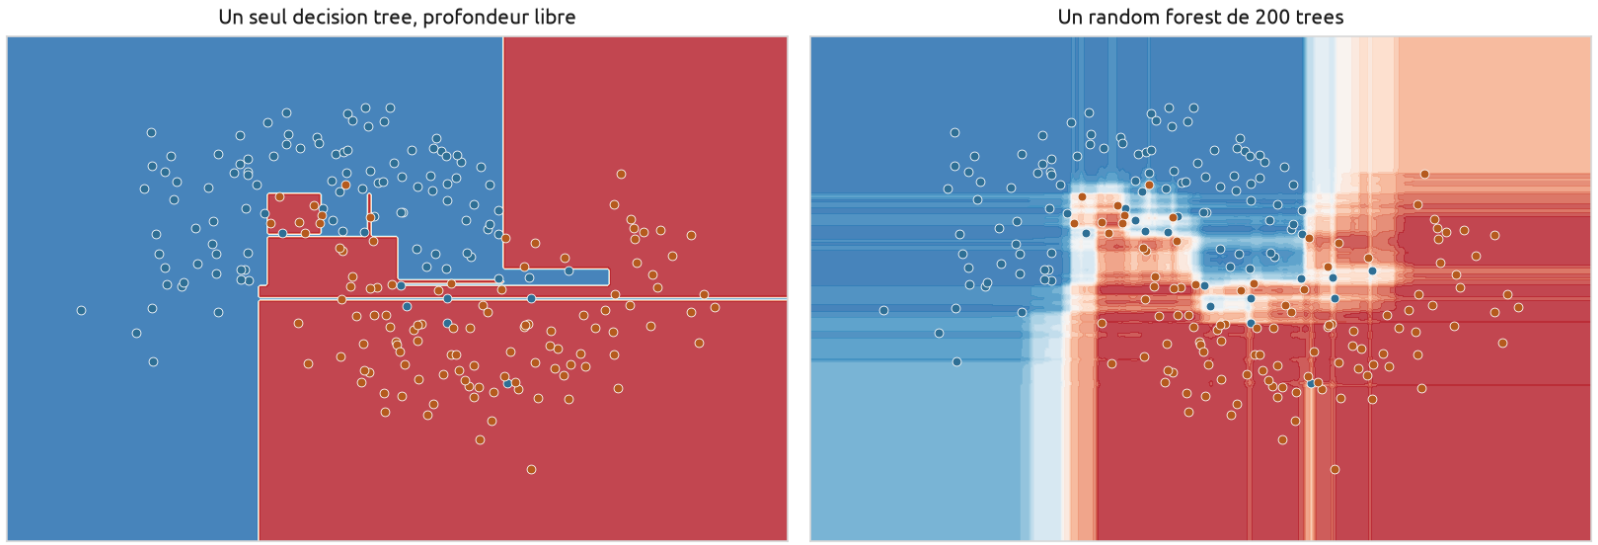
Le même decision tree, vu comme une suite de questions



À gauche l'espace découpé, à droite le même decision tree vu comme une suite questions. Chaque noeud demande « cette feature dépasse-t-elle ce seuil ? », donc les frontières sont toujours des angles droits, et l'échelle des colonnes n'a aucune importance.

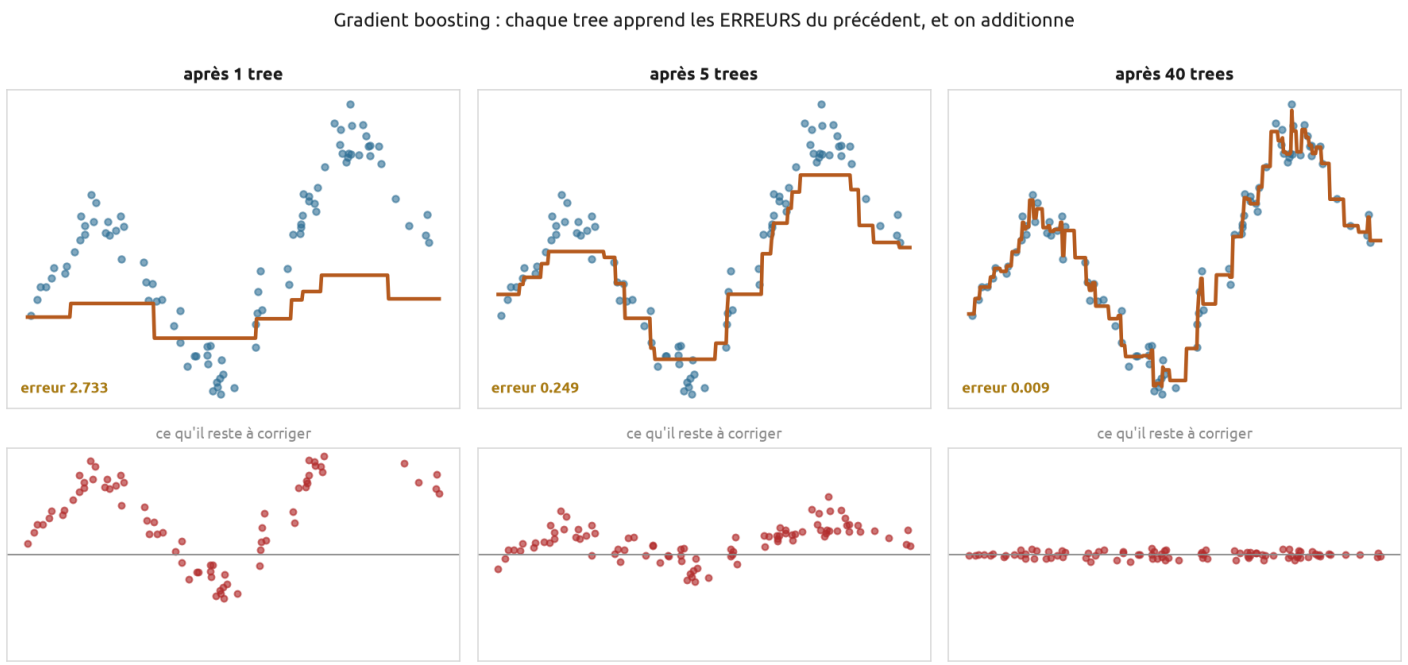
Random forest : pourquoi moyenner marche

Un decision tree seul découpe au plus près de ses exemples. Moyenner 200 trees entraînés sur des échantillons différents lisse la frontière.



À gauche un seul decision tree, qui découpe au plus près de ses exemples et attrape le bruit avec. À droite 200 trees entraînés sur des échantillons on moyenne les votes : la frontière se lisse, parce que les erreurs particulières de chaque tree ne se répètent pas.

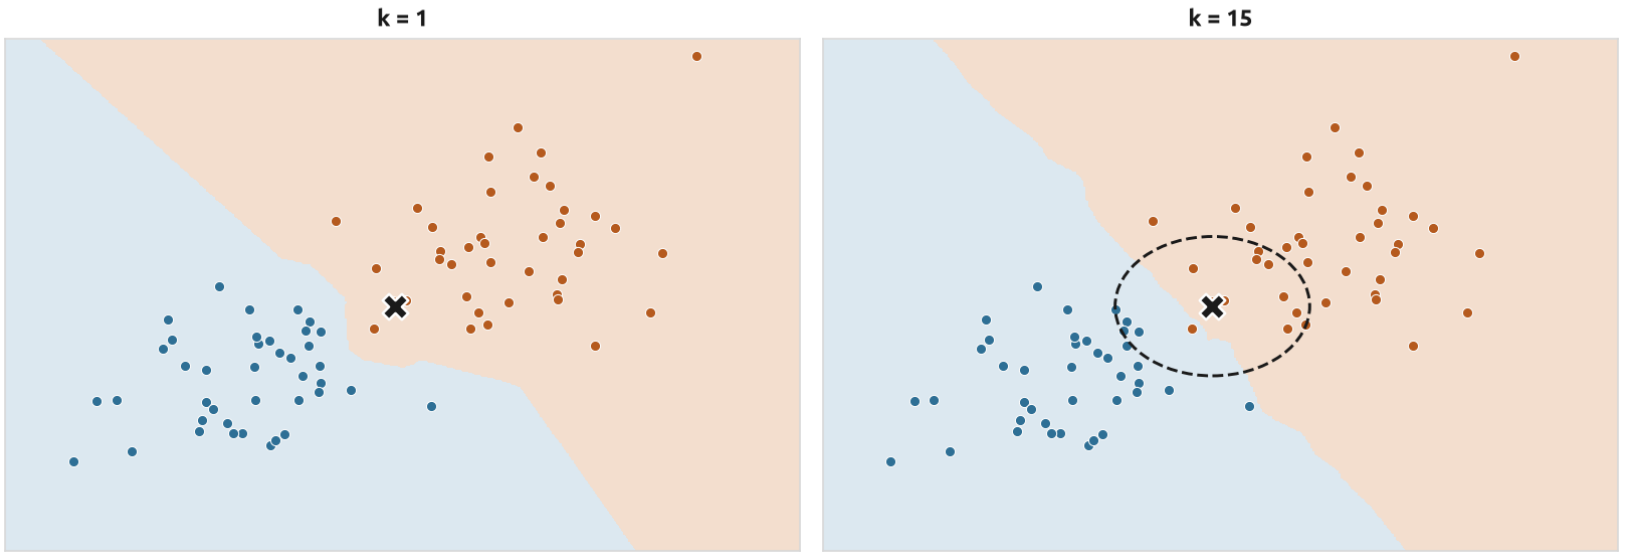
Gradient boosting : corriger ses propres erreurs



Le random forest fait voter des trees entraînés en parallèle. Le gradient boosting fait autre chose : chaque tree apprend **ce que les précédents ont raté**, et on additionne. En bas, ce qu'il reste à corriger à chaque étape, qui s'aplatit. L'erreur passe de 2,733 à 0,249 puis à 0,009.

k-nearest neighbours : aucun entraînement du tout

k-nearest neighbours : la croix prend la classe majoritaire dans son cercle. k petit colle au bruit, k grand lisse.



La croix prend la classe majoritaire parmi ses k voisins. Il n'y a rien à entraîner : le modèle EST le jeu de données. A gauche k=1, qui colle au bruit. A droite k=15, qui lisse. C'est le même compromis que sur la figure sous-apprentissage et sur-apprentissage du bloc A.

Les cinq, résumés

Et aucun des cinq n'a besoin que vous sachiez le démontrer.

modèle	ce qu'il trace	scaling ?	lisible ?
linear regression	une droite	utile	oui, les coefficients
logistic regression	une frontière droite	utile	oui
decision tree	des angles droits	inutile	oui, les questions
random forest, boosting	des angles droits moyennés	inutile	moins
k-nearest neighbours	des cellules autour des points	critique	non

Un séjour n'est pas un patient, et ça coûte 0,0052 d'AUC

45 694 séjours sur 99 343 appartiennent à quelqu'un qui revient. Un patient revient 40 fois.

découpage	patients des deux côtés	AUC
par ligne, `train_test_split`	7 856	0,6397
par patient, `GroupShuffleSplit`	0	0,6345

Quatre modèles, et leurs accuracy sont indiscernables

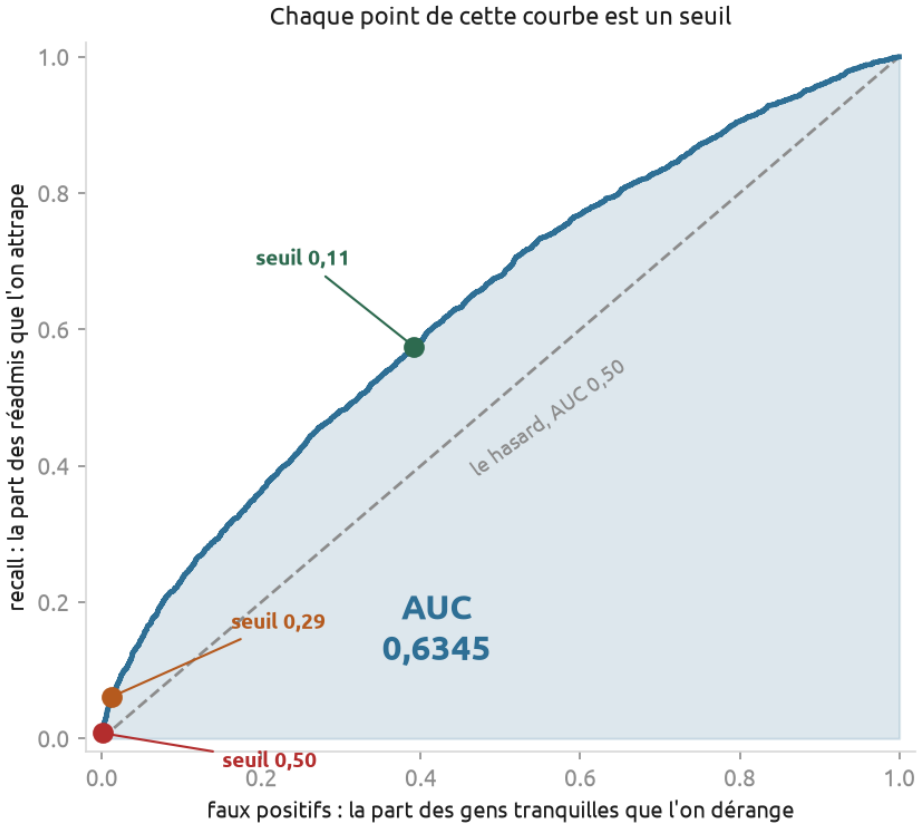
Mesuré sur 24 795 séjours de test, découpés par patient, graine 42.

modèle	accuracy	recall	AUC
toujours non, la baseline	0,8862	0,0000	0,5000
logistic regression	0,8863	0,0206	0,6314
random forest	0,8861	0,0004	0,6279
gradient boosting	0,8863	0,0078	0,6345

Les quatre accuracies sont identiques. Les AUC vont de 0,50 à 0,64.

Les modèles classent donc réellement les patients du plus au moins à risque. Ils ne franchissent simplement jamais le seuil de 0,50, parce qu'aucun patient n'atteint une probabilité aussi élevée dans un problème à 11 % de base.

La courbe ROC, et ce que l'AUC mesure vraiment



Les deux axes sont deux coûts opposés

Monter, c'est attraper plus de réadmis. Aller à droite, c'est déranger plus de gens qui allaient bien. On ne peut pas faire l'un sans l'autre, et le seuil choisit où l'on se place.

Le seuil par défaut est dans le coin

0,50 donne 0,0078 de recall pour 0,0009 de faux positifs. On ne dérange personne, et on n'attrape personne non plus. La courbe le montre d'un coup d'oeil.

Ce que l'AUC veut dire, concrètement

Prenez au hasard un patient réadmis et un patient qui ne l'a pas été. L'AUC est la probabilité que le modèle donne le score le plus élevé au premier.

0,6345 : il y arrive 63 fois sur 100, et se trompe 37 fois sur 100. Le hasard ferait 50.

Vérifié plutôt qu'affirmé : 200 000 paires tirées au sort donnent 0,6348, contre 0,6345 calculé. La même chose.

Chaque point de la courbe est **un seuil**. Monter, c'est attraper plus de réadmis ; aller à droite, c'est déranger plus de gens qui allaient bien. L'AUC est l'aire sous cette courbe, et la diagonale, le hasard, vaut 0,50.

Le recall au seuil par défaut

0,78 %

Le meilleur modèle attrape 22 réadmissions sur 2 822.

L'accuracy est de 88,63 %, la meilleure du tableau. Et le système est parfaitement inutile. Une accuracy sans son taux de base et sans son recall n'est pas un résultat, c'est un chiffre.

Les quatre nombres d'une matrice de confusion

true positive réadmis, et le modèle l'avait signalé. Le patient entre dans un programme de suivi.

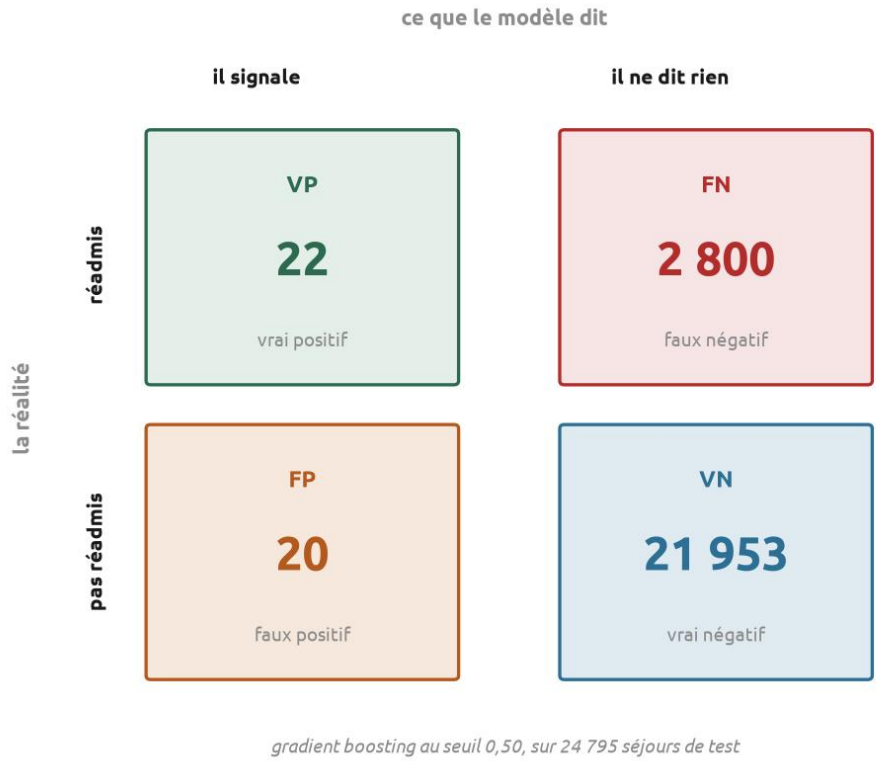
false positive pas réadmis, mais signalé. On a appelé quelqu'un pour rien, et cela coûte un peu.

false negative réadmis, et le modèle n'a rien dit. Un séjour complet, et cela coûte beaucoup.

true negative pas réadmis, rien signalé. Le cas de loin le plus fréquent, et celui qui gonfle l'accuracy.

Le point ces quatre cases n'ont pas le même prix. Une métrique qui les traite à égalité ne peut pas représenter la décision.

Les quatre cases, posées, et les cinq formules



gradient boosting au seuil 0,50, sur 24 795 séjours de test

accuracy	(VP + VN) / tout (22 + 21 953) / 24 795	**0,8863** *excellente, et elle ment*
precision	VP / (VP + FP) 22 / 42	**0,5238** *acceptable*
specificity	VN / (VN + FP) 21 953 / 21 973	**0,9991** *quasi parfaite*
recall	VP / (VP + FN) 22 / 2 822	**0,0078** *le modèle rate 99,2 % des cas*
F1	2 x precision x recall / (precision + recall)	**0,0154** *la moyenne qui refuse de mentir*

Les mêmes quatre nombres. Trois métriques disent excellent, deux disent catastrophique.

Le même modèle, les mêmes 24 795 séjours. `accuracy` dit 0,8863, `specificity` dit 0,9991, et `recall` dit 0,0078. Trois métriques excellentes et deux catastrophiques, calculées sur les **mêmes quatre nombres**.

Premier essai : une matrice de coût, et un résultat absurde

Hypothèses : une réadmission manquée 8 000 EUR, une fausse alerte 80 EUR.

seuil	coût	alertes	réadmissions attrapées
0,50 par défaut	22 401 600 EUR	42	22 sur 2 822
0,01 optimal	1 757 840 EUR	24 795	2 822 sur 2 822

Ce que l'on croit, ce que la mesure dit

ON CROIT

Le seuil optimal économise 92,2 %, donc c'est le bon seuil.

LA MESURE DIT

Ce seuil alerte sur **100 % des patients**. Il dit d'appeler tout le monde, et dans ce cas le modèle ne sert plus à rien du tout.

LA BONNE VERSION

Quand l'optimum consiste à tout déclencher, ce n'est pas le seuil qui est bon, c'est l'hypothèse qui est fausse. Ici elle est cachée : la matrice suppose qu'un appel évite toujours la réadmission.

La version honnête tient en une ligne d'arithmétique

```
# un programme de sortie coûte 500 EUR par patient inscrit
# et evite 20 % des readmissions de ceux qu'il inscrit

seuil_rentable = 500 / (0.20 * 8000)      # -> 0.312
```

Inscrire un patient devient rentable au-dessus de 31,2 % de risque. Ce n'est plus un réglage que l'on cherche, c'est un calcul que l'on pose.

Et la réponse change complètement

34 réadmissions évitées, mesuré sur le test set.

décision	patients inscrits	bénéfice net
seuil 0,29, le meilleur	434 sur 24 795, soit 1,8 %	+58 200 EUR
inscrire tout le monde	24 795, soit 100 %	-7 882 300 EUR

Le livrable, et il ne dépend d'aucune hypothèse de coût

42,5 %

Rendement sur les 200 patients les mieux classés, contre 11,4 % au hasard.

Près de quatre fois plus de réadmissions trouvées, à nombre d'appels constant. Si une infirmière peut faire 200 appels, voilà la liste. C'est un résultat que l'on peut défendre devant quelqu'un qui conteste vos hypothèses de prix.

Ce que le bloc C a établi

Le taux de base d'abord 11,39 %, donc 88,61 % est le plancher et non un succès.

Deux métriques, deux questions l'accuracy demande si vous avez raison, l'AUC si vous savez classer. La seconde construit une liste de priorités.

Le seuil est une décision il n'appartient pas au modèle, et il se calcule à partir du coût et de l'efficacité de l'action.

Une matrice de coût cache une hypothèse celle que l'intervention fonctionne. Écrivez-la, ou elle décidera à votre place.

La capacité tranche le seuil optimal est souvent impossible à tenir, et c'est le nombre d'appels disponibles qui décide.

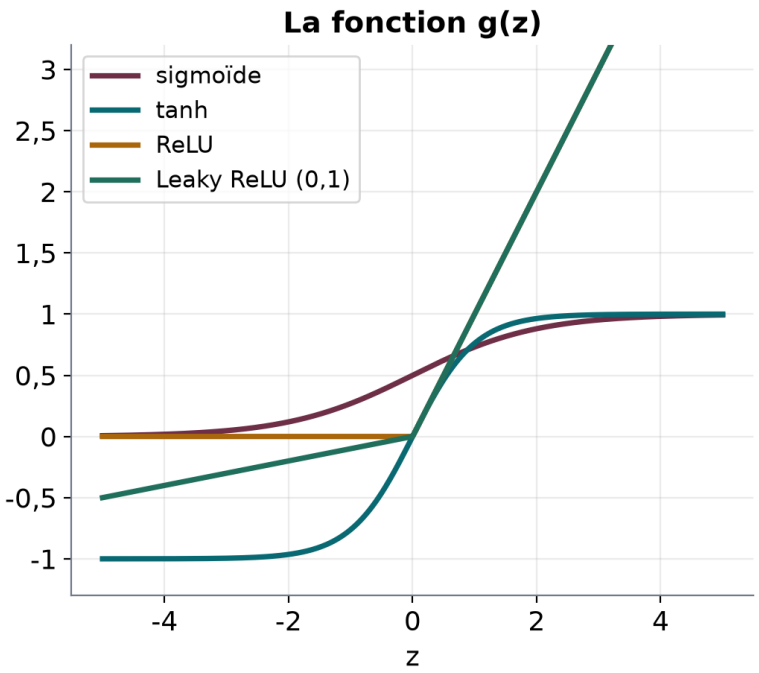
D Neural networks

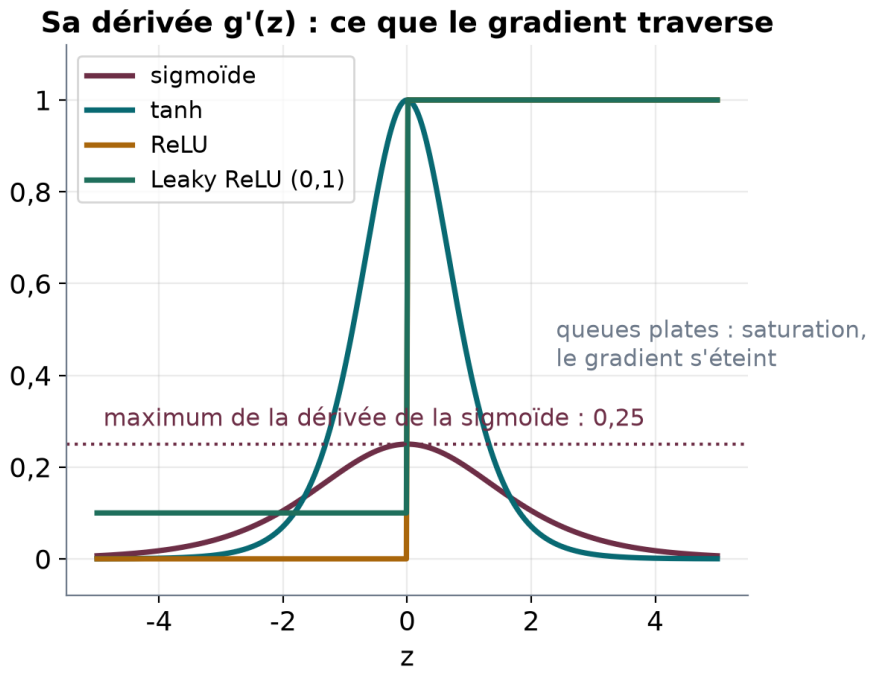
Un neurone est une somme pondérée suivie d'une fonction. Tout le reste est de la répétition, de la plomberie, et quatre réglages dont trois peuvent tout casser.

Un neurone multiplie ses entrées par des poids, les additionne, et passe le résultat dans une fonction.

C'est tout. Un réseau est un empilement de ces opérations, et la seule chose qu'il apprend est la valeur des poids.

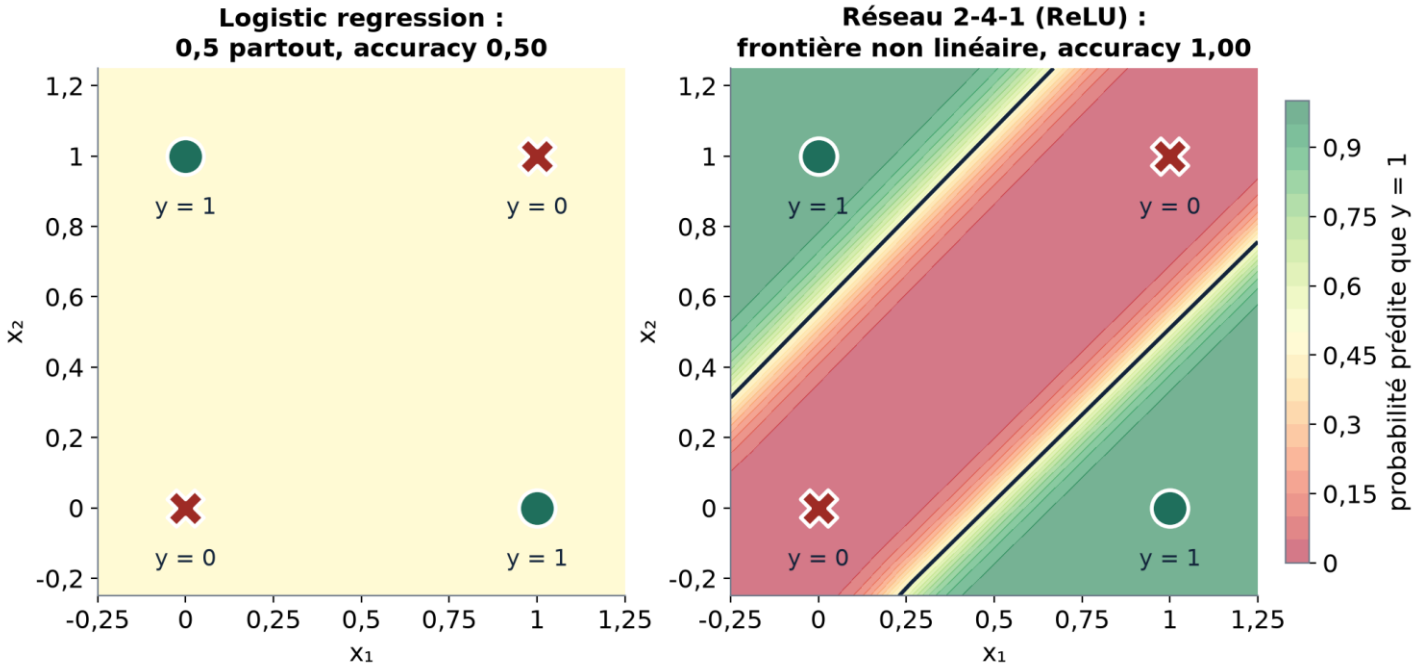
Les fonctions d'activation, et pourquoi il en faut une





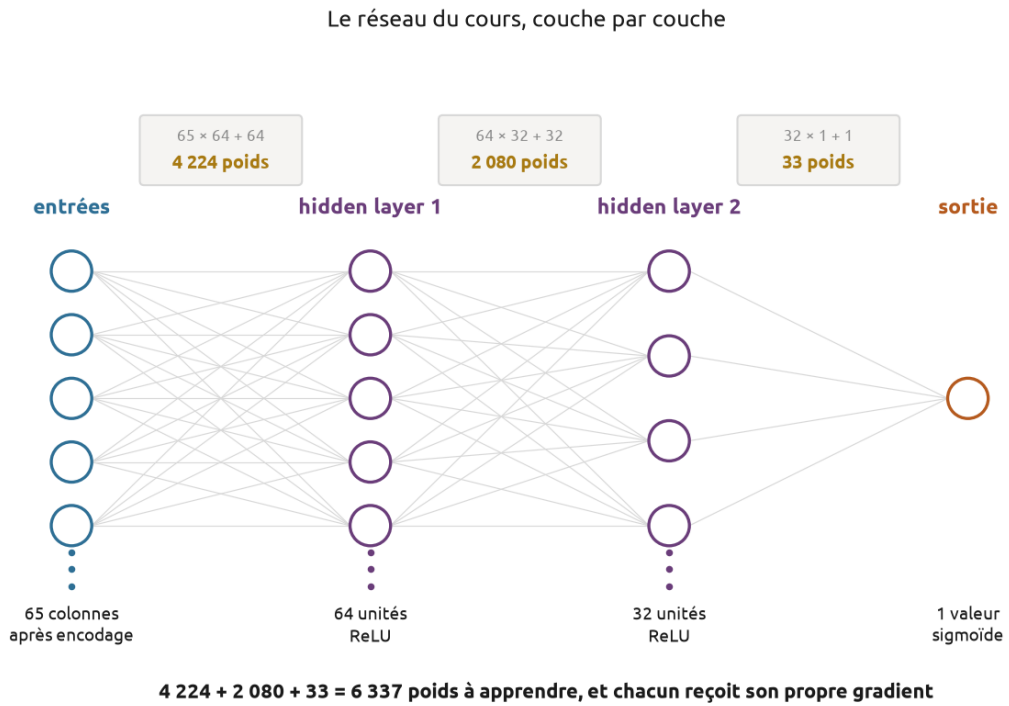
Sans fonction non linéaire entre les couches, empiler dix couches revient exactement à une seule : une somme de sommes pondérées reste une somme pondérée. C'est la non-linéarité qui donne sa puissance au réseau, pas la profondeur en elle-même.

Le problème que la linear regression ne sait pas résoudre



À gauche une logistic regression, qui ne peut tracer qu'une droite et se trompe donc partout. À droite un petit réseau 2-4-1, qui plie sa frontière. La différence n'est pas la taille du modèle, c'est sa capacité à courber.

Le réseau du cours, couche par couche



65 colonnes en entrée, une hidden layer de 64 unités, une autre de 32, et une sortie. Les poids se comptent couche par couche : 4 224, puis 2 080, puis 33. Au total **6 337 poids**, et chacun reçoit son propre gradient à chaque pas.

JOUR 1 · THEORIE S0 A S4

Le calcul, en cinq minutes et pas une de plus

La seule notation utile : de combien la loss bouge si je bouge ce poids.

Une dérivée est une pente elle dit de quel côté c'est la descente, et à quel point c'est raide. Rien d'autre.

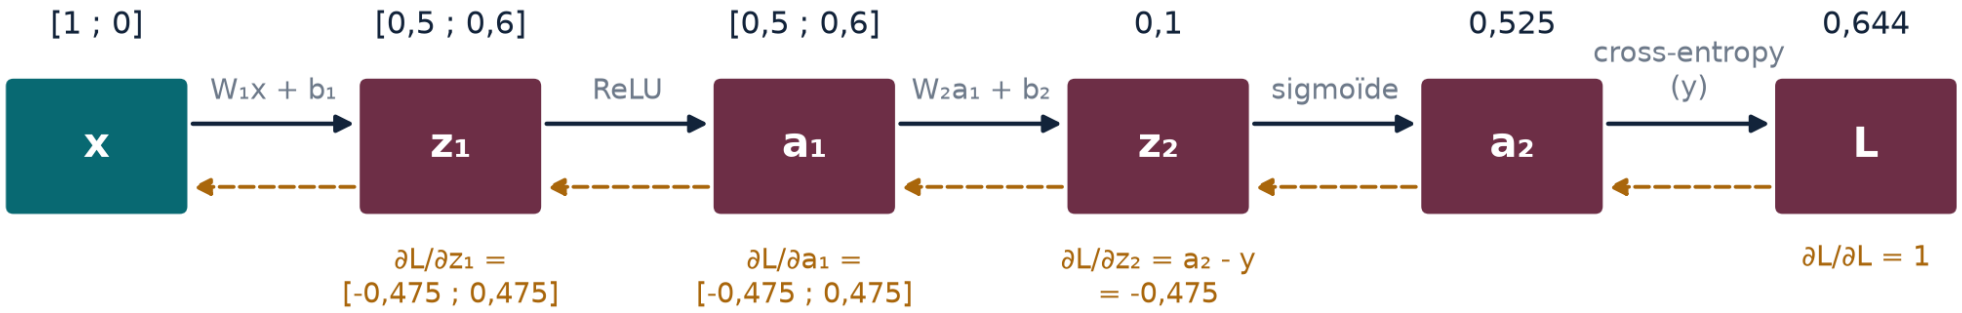
Un gradient est une pente dans plusieurs directions avec un poids on obtient un nombre, avec 6 337 poids on en obtient 6 337.

La chain rule suit la propagation si la loss dépend de la dernière couche, qui dépend de la précédente, un changement en amont se propage jusqu'au bout.

Backpropagation c'est le nom de cette comptabilité parcourue à l'envers, et c'est toute la magie du sujet.

Ce que loss.backward() parcourt réellement

Forward pass (gauche → droite) : on calcule les valeurs

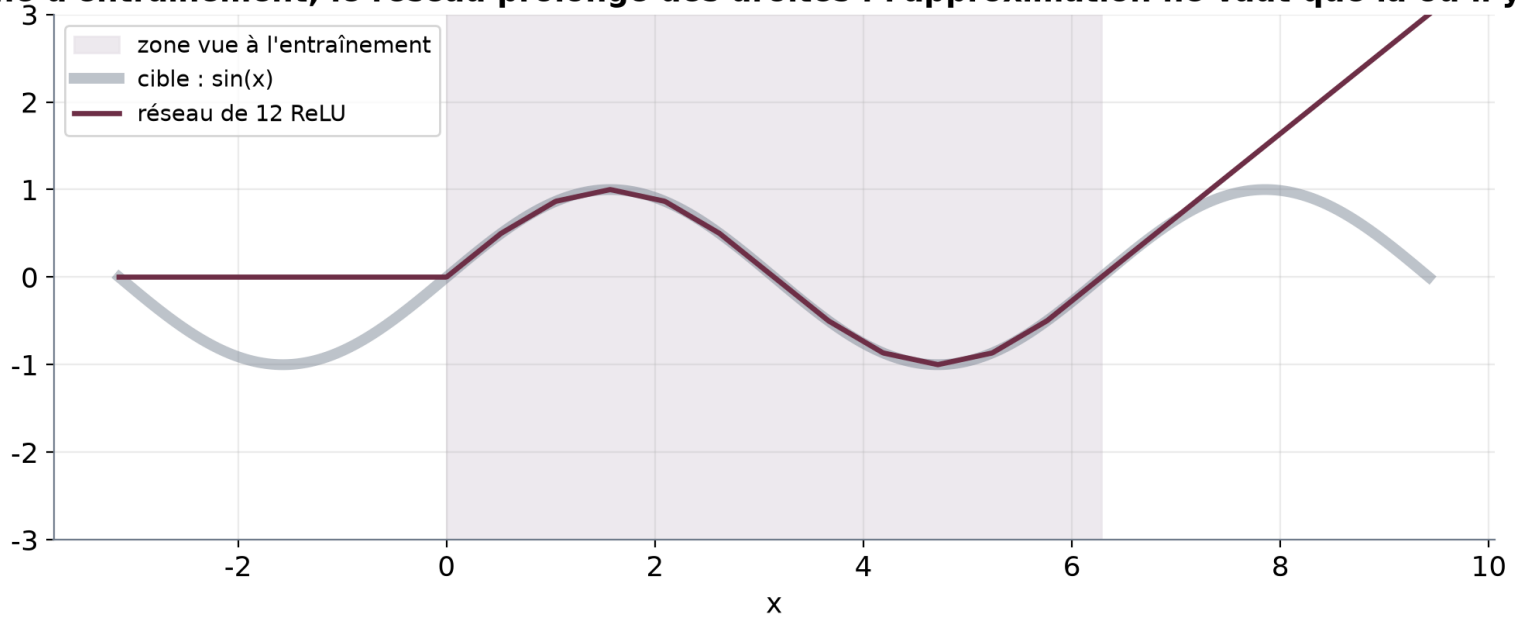


Backward pass (droite → gauche) : chaque flèche multiplie par la dérivée locale de son opération

Le forward pass va de gauche à droite et produit une prédiction. Le backward pass revient de droite à gauche et dépose, sur chaque poids, de combien la loss changerait si on le bougeait. Chaque poids obtient le sien.

Ce qu'un réseau sait faire, et ce qu'il ne sait pas

Hors de la zone d'entraînement, le réseau prolonge des droites : l'approximation ne vaut que là où il y a des données



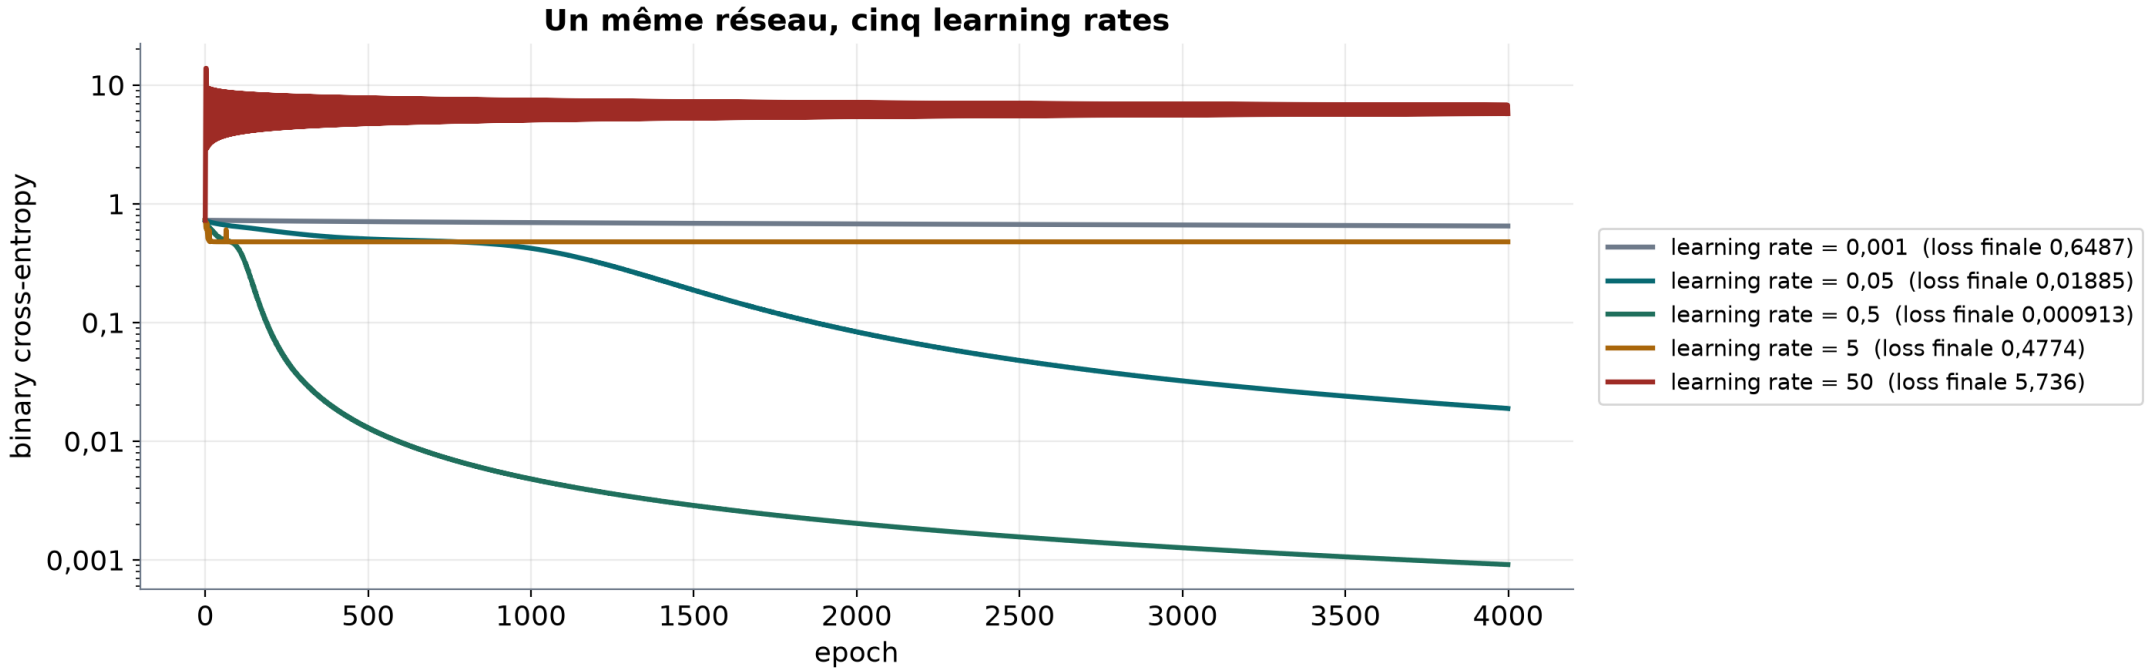
À l'intérieur de la zone où il a vu des exemples, le réseau approche la courbe de très près. Dès qu'il en sort, il part n'importe où. Un réseau **interpole** de façon fiable ; hors de cette zone il répond quand même, et n'importe quoi. Rien dans son score d'entraînement ne vous préviendra.

Les cinq lignes de toute boucle d'entraînement

```
optimiseur.zero_grad()              # oublier les gradients du pas precedent
predictions = model(X)              # forward pass
loss = loss_function(predictions, y)
loss.backward()                     # un gradient pour CHAQUE poids
optimiseur.step()                   # un pas vers le bas
```

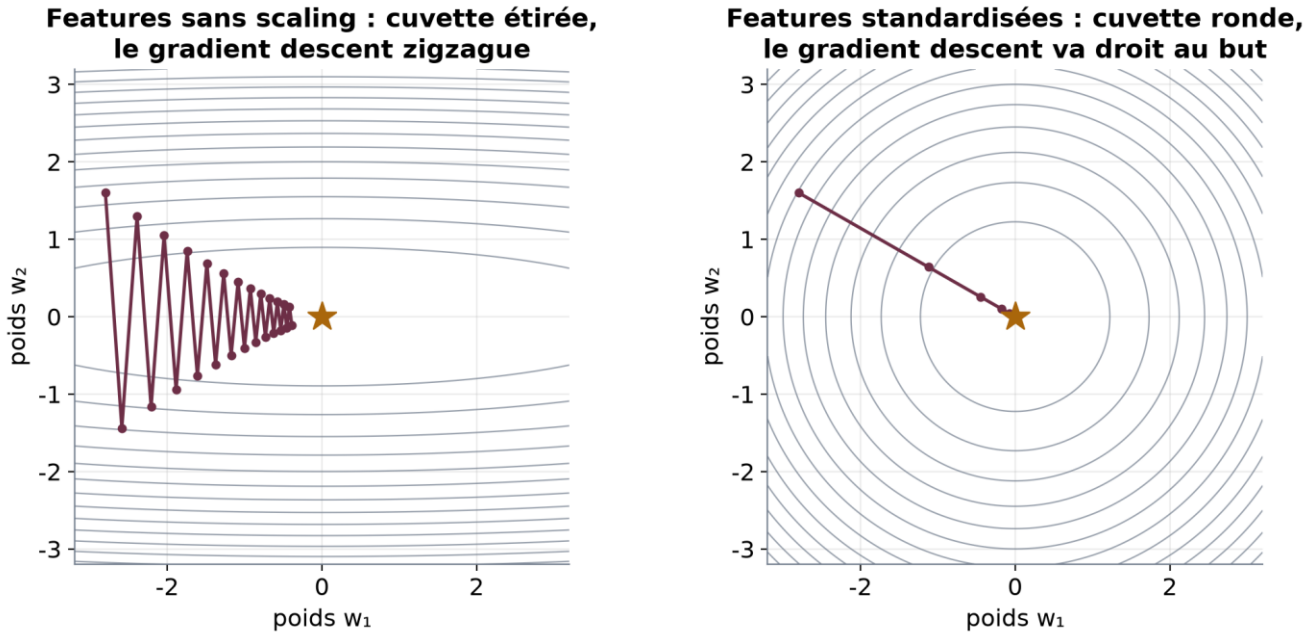
Toute boucle d'entraînement PyTorch jamais écrite tient dans ces cinq lignes. Le TD de demain vous les fera remplir une par une.

Le learning rate, le seul réglage qui casse tout



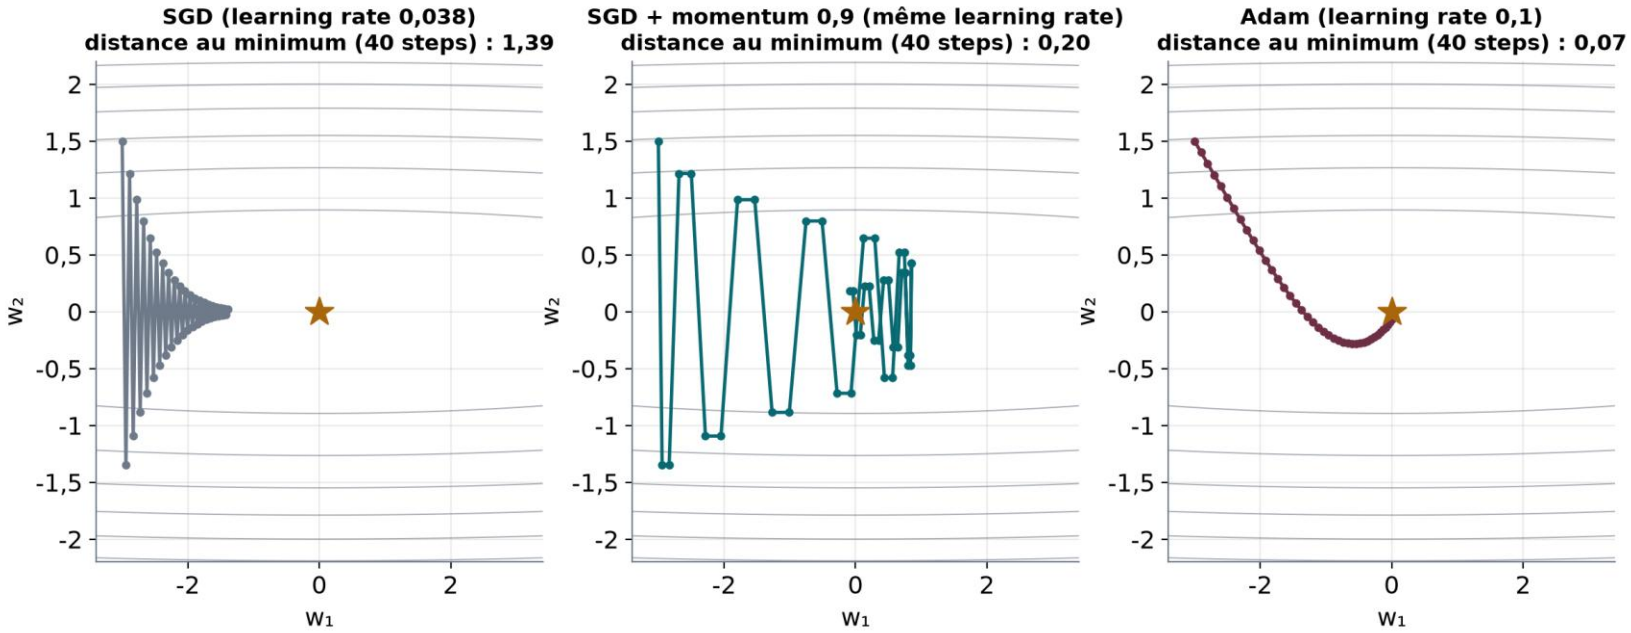
Trop petit, le modèle n'arrive nulle part dans le temps imparti. Trop grand, il diverge et finit plus mauvais que s'il n'avait rien appris. Entre les deux, une plage étroite que personne ne connaît à l'avance.

Pourquoi le scaling change tout pour un réseau



À gauche une cuvette ronde : la descente va droit au fond. À droite la même cuvette étirée, parce qu'une colonne est en milliers et l'autre en unités : la descente zigzague et met bien plus longtemps. Mettre les colonnes à la même échelle, c'est rendre la cuvette ronde.

Les optimiseurs : la même descente, en mieux guidée



Trois trajectoires sur le même ravin. SGD suit la pente et oscille. Le momentum garde de l'élan et traverse. Adam ajuste le pas pour chaque poids séparément, ce qui est la raison pour laquelle on s'en sort sans régler le learning rate aussi finement que la partie précédente le laissait craindre.

Quatre façons de casser le réseau, mesurées sur nos données

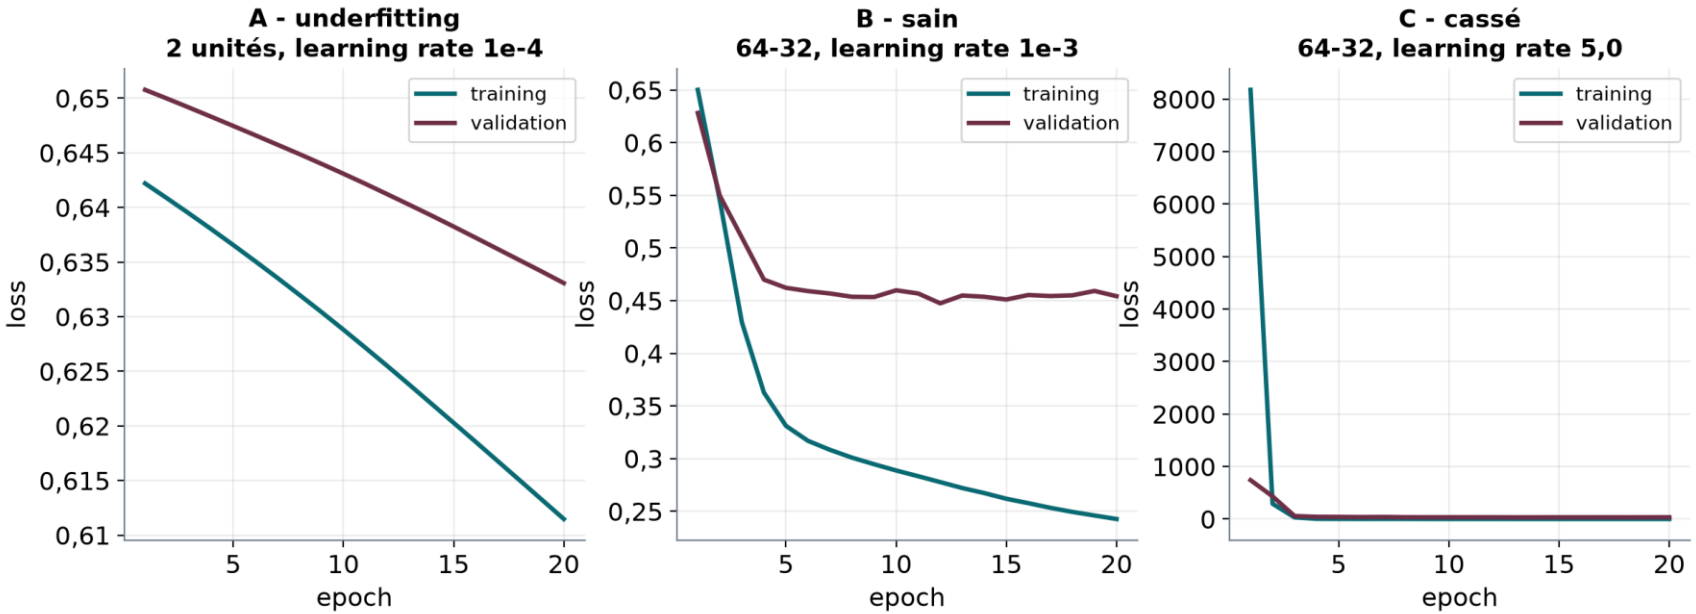
Même architecture, même graine, mêmes données. Seul le réglage change.

réglage	AUC	loss finale
learning rate 1e-3, correct	0,6194	0,3439
learning rate 1,0, trop grand	0,5000	0,3547
learning rate 1e-6, trop petit	0,4583	0,7088
sans scaling des numériques	0,6079	0,3444

Un decision tree n'a aucun de ces quatre réglages.

Pas de learning rate, pas d'architecture, pas de scaling, pas de décision sur le moment d'arrêter.
C'est le vrai argument, et il n'apparaît dans aucune comparaison de performance.

Les trois allures d'une courbe de loss, et ce qu'elles disent



A, les deux courbes descendent à peine : le modèle est trop petit ou le learning rate trop faible. B, l'allure saine : la training descend, la validation se stabilise. C, la loss explose puis s'effondre : le learning rate est trop grand et le réseau a divergé.

Alors, est-ce que le réseau a payé ce qu'il coûte ?

	gradient boosting	neural network
AUC	0,6345	0,6194
bénéfice net du programme	58 200 EUR	18 900 EUR
temps d'entraînement	0,4 s	0,7 s
taille sur disque	159 Ko	25 Ko
réglages à choisir	aucun	quatre

À REFAIRE EN TD 4

Un écart d'AUC qui paraît négligeable

39 300 EUR

L'écart de bénéfice entre les deux modèles, sur le même programme.

Leurs AUC diffèrent de 0,0151, et leur classement envoie des patients différents dans les 434 places. Attention à la formulation : ce ne sont pas **39 300 EUR par point d'AUC**. Les deux modèles diffèrent par bien autre chose que leur AUC. Ce qui se transfère est la démarche, pas le taux de change.

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

Le deep learning est plus performant, donc il faut l'utiliser.

LA MESURE DIT

Sur ces données hospitalières en tableau, le **gradient boosting** gagne sur l'AUC, gagne sur le bénéfice, ne demande aucun réglage, et donne en prime l'importance des variables. Le network ne gagne que sur la taille du fichier.

LA BONNE VERSION

Sur des données en tableau, commencez par une baseline, puis essayez un gradient boosting. Les networks gagnent quand les features doivent être découvertes au lieu d'être mesurées : des pixels, du son, du texte. C'est le sujet du jour 3.

Ce que le bloc D a établi

Un neurone est une somme pondérée et un réseau en est un empilement. La non-linéarité fait le reste.

Cinq lignes suffisent zero_grad, forward, loss, backward, step. Vous les écrirez demain.

Trois réglages sur quatre peuvent tout casser et l'un d'eux donne un résultat pire que le hasard, en silence.

Sur du tableau, le gradient boosting gagne 0,6345 contre 0,6194, et 58 200 EUR contre 18 900 EUR.

Traduisez toujours l'écart 0,015 d'AUC ne dit rien seul. 39 300 EUR d'écart de bénéfice, si.

E

Quand les lignes ont un ordre

Une seule chose change : les lignes ne sont plus interchangeables. Et presque tout ce que les blocs B, C et D ont installé cesse de fonctionner.

Combien de passages aux urgences demain ?

736 jours de relevés quotidiens, quatre départements bretons, en open data. Pas la France entière : quatre départements, et le dire change ce que l'on peut conclure.

Le lundi n'est pas le dimanche, et ce n'est pas un artefact

Moyenne par jour de la semaine sur 736 jours.

jour	passages	jour	passages
lundi	2 508	vendredi	2 322
mardi	2 307	samedi	2 253
mercredi	2 231	dimanche	2 179
jeudi	2 277	écart lundi / samedi	+11,3 %

L'autocorrélation, et ce qu'elle vous dit avant tout modèle

Ce que c'est la corrélation de la série avec elle-même, décalée de k jours. Elle répond : hier ressemble-t-il à aujourd'hui ?

À 1 jour : +0,2521 hier n'est pas un très bon indice. Les urgences varient beaucoup d'un jour à l'autre.

À 7 jours : +0,5930 la semaine dernière, en revanche, oui. C'est la signature d'une activité qui dépend du jour de la semaine.

À 364 jours : +0,4874 et il y a aussi une structure annuelle, les épidémies hivernales.

Ce que cela décide votre baseline. Ici ce sera « la même valeur que la semaine dernière », pas « la même valeur qu'hier ».

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

On mélange les lignes et on fait un split 80 / 20, comme d'habitude.

LA MESURE DIT

Sur une série temporelle, mélanger place des jours de janvier 2024 dans l'entraînement et des jours de décembre 2023 dans le test. Le modèle apprend donc sur l'avenir pour prédire le passé.

LA BONNE VERSION

On coupe dans le temps, toujours : on entraîne sur le début, on testé sur la suite. Et on recommence plusieurs fois, en avançant la coupure. Cela s'appelle un backtest, ou walk-forward.

Pour chaque feature : au moment où je dois produire la prévision, ce nombre existe-t-il déjà ?

C'est la même question qu'au bloc B, et elle dépend ici d'une chose que l'on oublie d'écrire : **l'horizon**. Prévoir le lendemain autorise la valeur de la veille. Prévoir à sept jours l'interdit, parce que le jour de la prévision cette valeur n'aura pas encore eu lieu.

À REFAIRE EN TD 5

Le backtest : douze plis, et le modèle gagne

On prévoit le lendemain. 12 plis de 7 jours, espacés de 28 jours.

méthode	MAE moyenne	min	max
naïf : comme hier	155,0	89,4	220,4
naïf saisonnier : comme la semaine dernière	123,9	45,0	225,0
moyenne des 28 derniers jours	136,8	38,1	204,0
gradient boosting sur lags	90,1	41,7	201,0

JOUR 1 · THEORIE S0 A S4

Ce que l'on croit, ce que la mesure dit

ON CROIT

Ce modèle fait 27 % de mieux, donc il est bon.

LA MESURE DIT

Il prévoit **le lendemain**, en connaissant la veille. Reposez la même question à sept jours d'horizon, sans la valeur de la veille, tout le reste identique : le modèle passe de **+27,3 % à -1,5 %**, et cesse donc de battre le naïf.

LA BONNE VERSION

Tout son avantage tenait à la valeur d'hier. Un score de prévision ne veut rien dire tant que l'horizon n'est pas écrit à côté, parce que c'est l'horizon qui décide quelles features existent.

Et la moyenne cache tout le reste

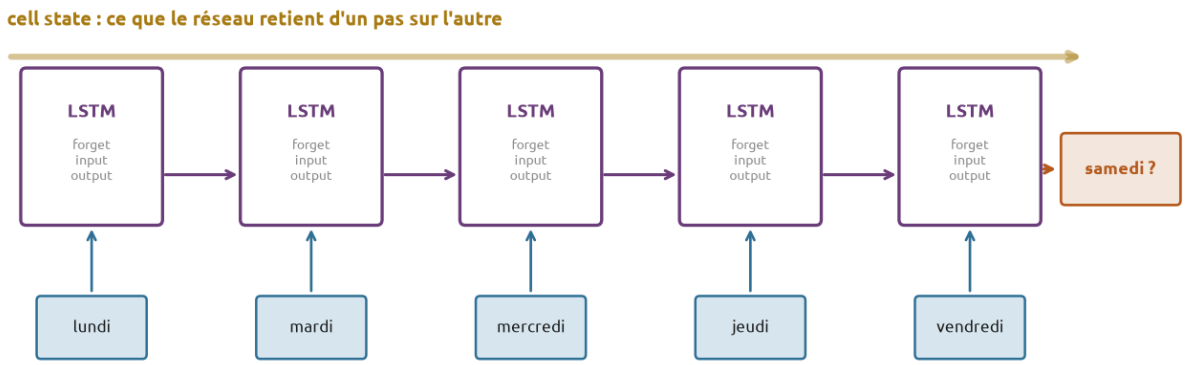
facteur 4,8

L'écart entre le meilleur et le pire des douze plis.

La MAE moyenne est de 90,1. Mais il y a des semaines à 41,7 et des semaines à 201,0, et personne ne sait d'avance dans laquelle on sera. Annoncer 90,1 sans l'étendue, c'est promettre une régularité que le modèle n'a pas.

Et la famille que tout le monde attend : le LSTM

LSTM : une cellule répétée, qui transporte un état le long de la séquence



C'est LA MÊME cellule à chaque pas : un seul jeu de poids, appliqué cinq fois.

Et chaque pas attend le précédent, donc rien ne se calcule en parallèle. C'est la limite qui a coûté sa place au LSTM.

Un LSTM lit la série pas à pas et transporte un état d'un jour sur l'autre. C'est la même cellule à chaque pas, avec un seul jeu de poids. Et chaque pas attend le précédent, donc rien ne se calcule en parallèle : c'est la limite qui lui a coûté sa place face aux transformers du jour 3.

Maintenant le même code, sur un autre indicateur du même fichier.

Mêmes dates, mêmes départements, mêmes features, mêmes plis, même graine. On change uniquement la colonne que l'on cherche à prévoir.

Le modèle perd contre le naïf

indicateur	autocorr 7 j	naïf	modèle	gain
passages totaux, tous âges	+0,5930	123,87	90,10	+27,3 %
passages covid, 5-14 ans	+0,0281	0,15	0,22	-42,8 %

La prévisibilité est une propriété du signal, pas de votre modèle.

Un plafond que l'on ne voit pas reste un plafond, et aucun réglage ne le soulève. Savoir le reconnaître avant d'y passer un mois est une compétence d'ingénieur, pas un aveu d'échec.

Et vous pouviez le savoir avant d'écrire une ligne

+0,59 contre +0,03

L'autocorrélation à 7 jours des deux indicateurs. Le TD en donnera les décimales.

C'est le même diagnostic qu'au début du bloc, utilisé pour une seconde fonction, bien plus utile : non pas choisir un baseline, mais décider s'il y a lieu de commencer. Tracez-la, mesurez le naïf, et demandez-vous s'il reste quelque chose à gagner.

Ce que la journée a établi, et ce qui vous attend demain

Bloc B une demande n'est pas un problème, et le meilleur score peut être le mauvais.

Bloc C le taux de base d'abord, le seuil est une décision, et la capacité tranche.

Bloc D sur du tableau, le gradient boosting gagne, et un écart d'AUC ne veut rien dire tant qu'il n'est pas traduit.

Bloc E on coupe dans le temps, la moyenne cache l'étendue, et la prévisibilité appartient au signal.

Et ensuite un dernier bloc : exactement les mêmes données qu'aux blocs C et D, mais sans la colonne à prédire.

F

Quand il n'y a pas de target

Mêmes patients, mêmes colonnes qu'aux blocs C et D. On retire simplement la colonne à prédire, et presque tout ce qui a servi aujourd'hui devient inutilisable.

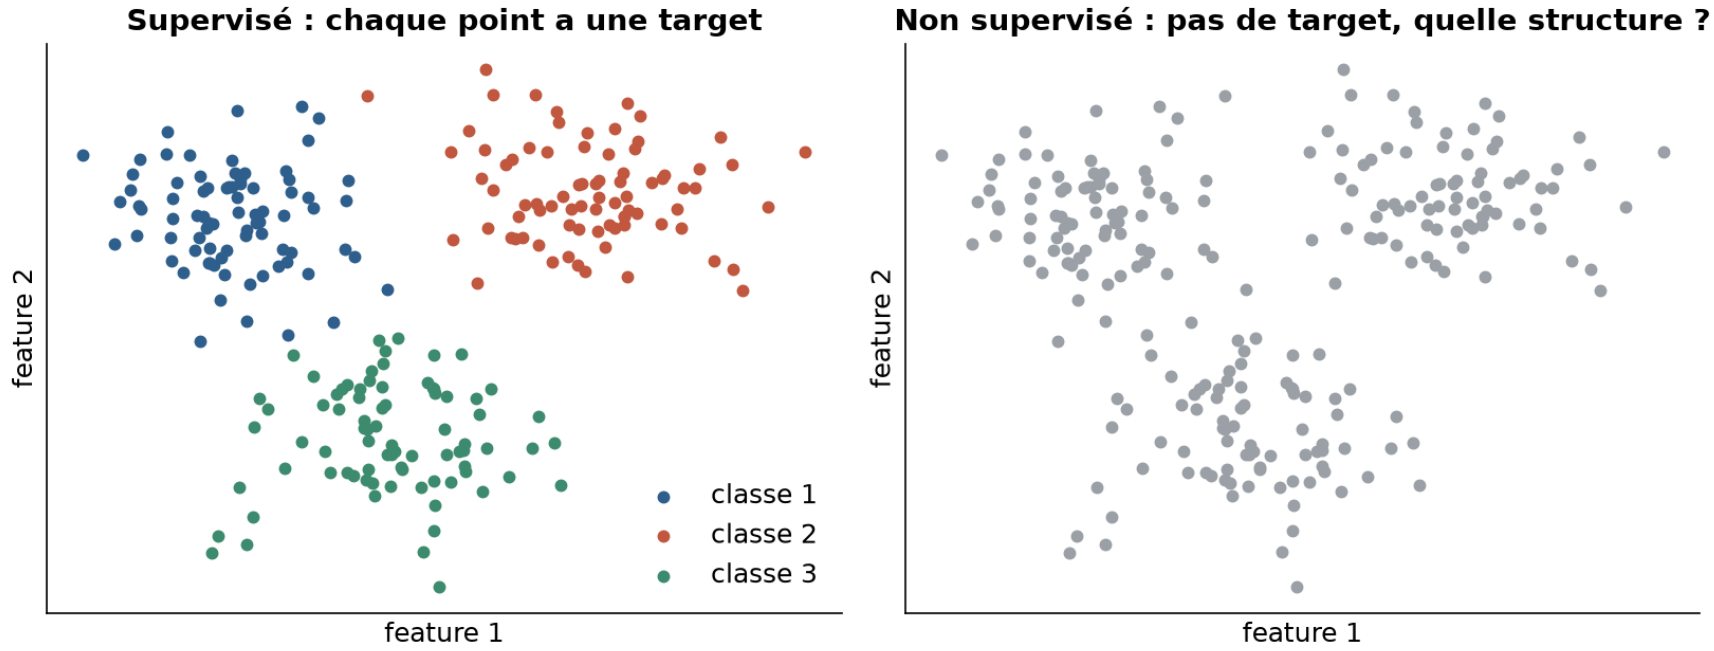
Jusqu'ici chaque modèle apprenait à prédire une target. Ici, il n'y en a pas.

On ne cherche plus à prédire une réponse connue, on cherche une structure. Des groupes, un résumé, ou ce qui ne ressemble à rien. Et la conséquence immédiate est qu'il n'y a plus rien contre quoi se vérifier.

Ce que l'on perd en retirant la target

	Supervised, blocs C et D	Unsupervised, ce bloc
Données	features X et target y	features X seulement
Question	prédire y pour un cas nouveau	quelle structure dans X ?
Évaluation	accuracy, AUC sur un test set	pas de vérité terrain
Risque principal	overfitting	voir une structure qui n'existe pas

La même donnée, deux questions



À gauche chaque point arrive avec sa classe : on apprend à la prédire et on mesuré l'erreur. À droite les mêmes points sans leur classe : on ne peut plus que constater des regroupements, et rien ne dit s'ils veulent dire quelque chose.

Trois familles, et une seule sera utile aujourd'hui

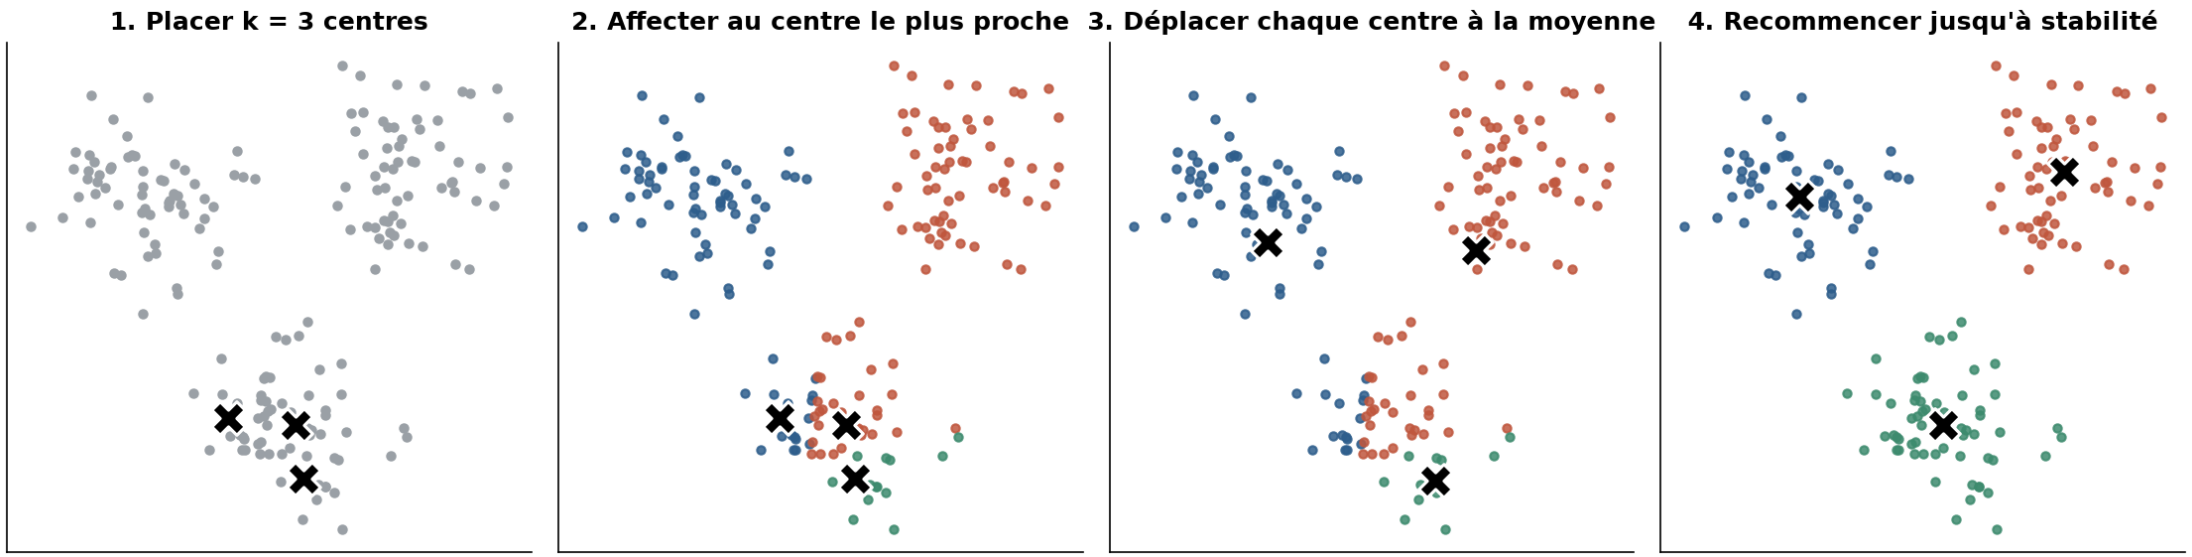
Clustering regrouper ce qui se ressemble. k-means, DBSCAN. Nous allons le mesurer et constater qu'il ne trouve rien ici.

Dimensionality reduction résumer beaucoup de colonnes en quelques-unes. PCA. Nous allons constater qu'il n'y a presque rien à résumer.

Anomaly detection repérer ce qui ne ressemble pas au reste. Celle-là va marcher, et elle va bien marcher.

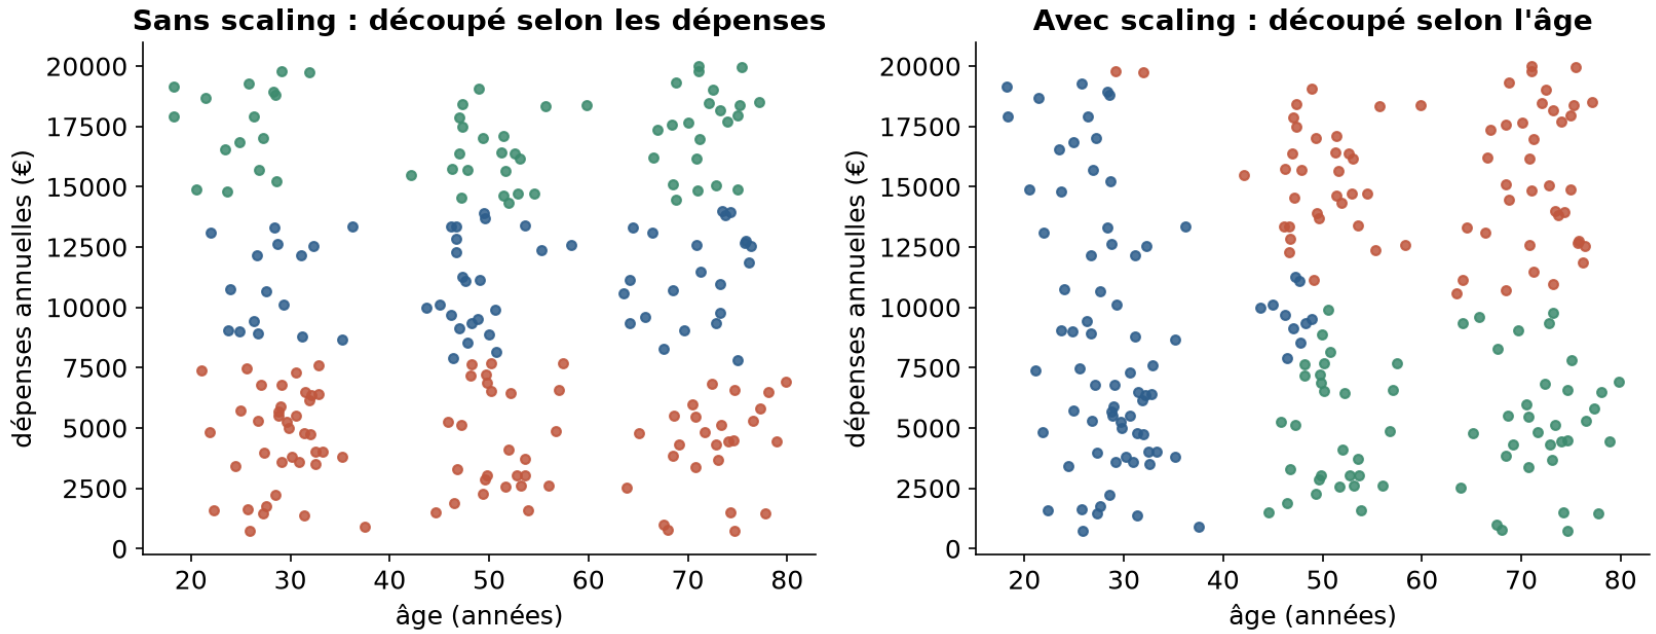
Le point commun aucune n'a de target, donc aucune ne peut vous dire toute seule si son résultat vaut quelque chose.

k-means, en trois gestes



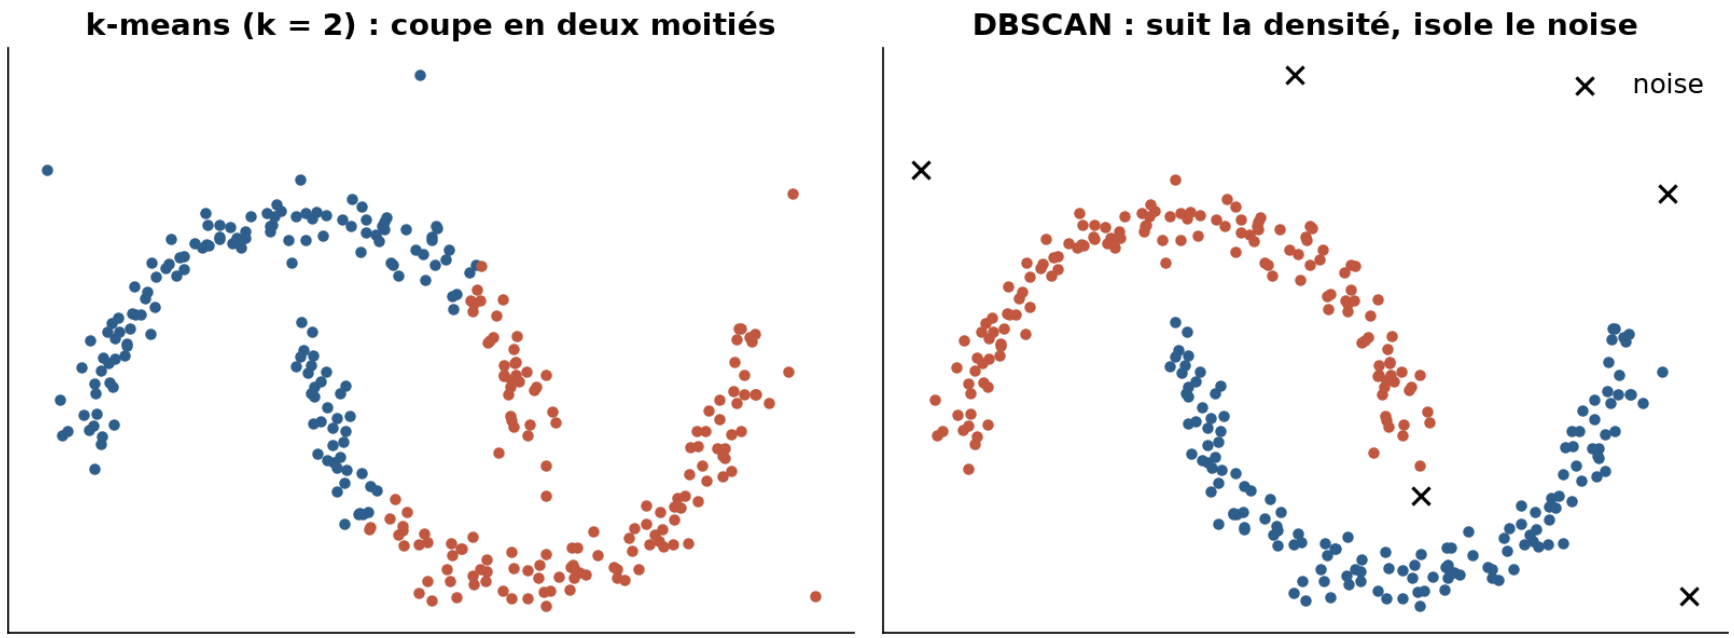
On place k centres au hasard, on attache chaque point au plus proche, on déplace chaque centre vers la moyenne de ses points, et on recommence. Les centres ne sont que des moyennées, et les frontières sont toujours droites.

Et le scaling décide des groupes que l'on trouve



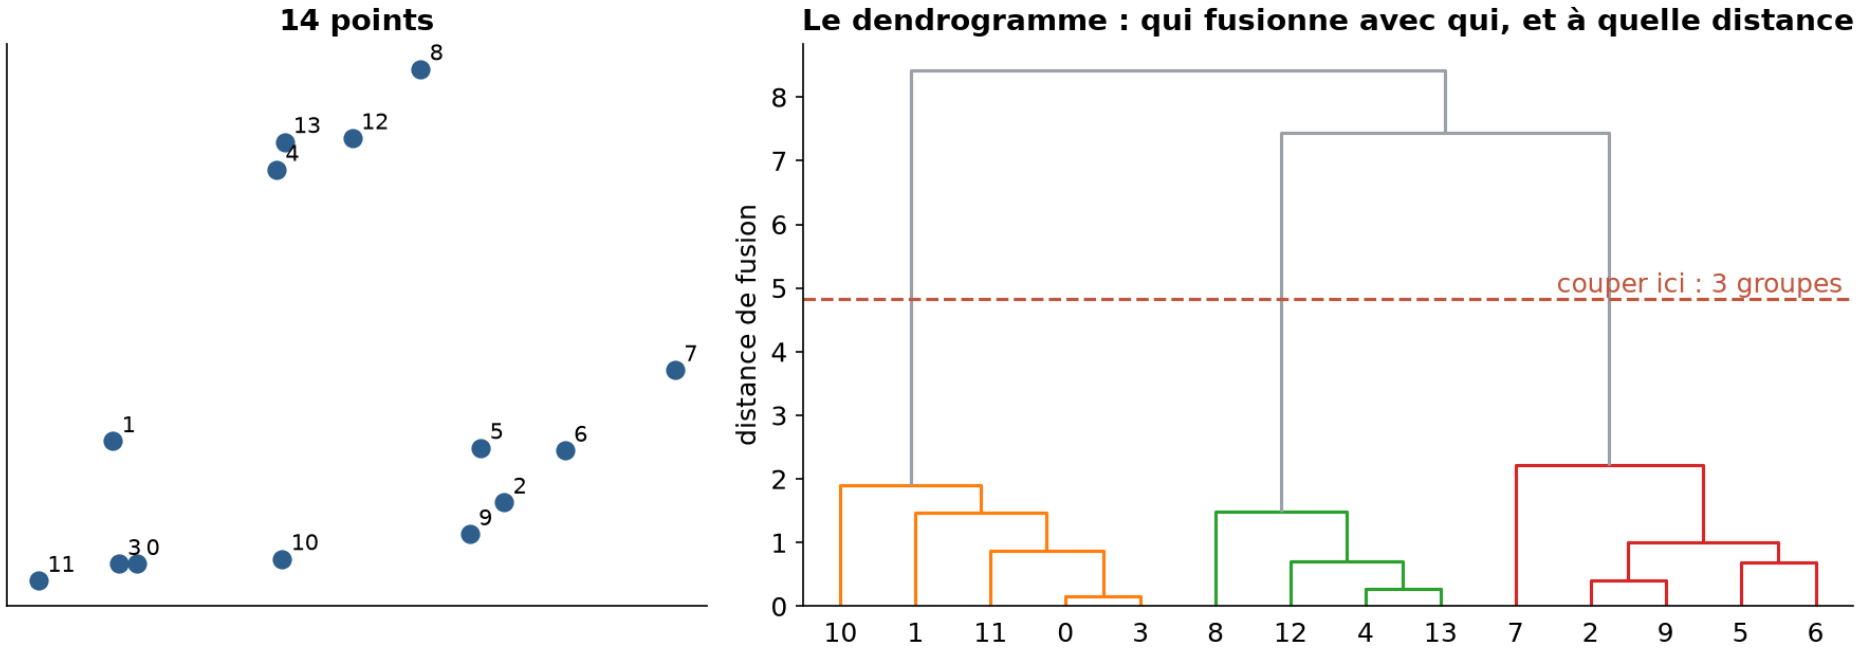
Les mêmes personnes, le même k-means. À gauche sans mise à l'échelle : les dépenses sont en milliers d'euros et l'âge en dizaines d'années, donc l'algorithme découpe selon les dépenses et ignore l'âge. À droite après mise à l'échelle : il découpe selon l'âge.

DBSCAN : une autre définition de ce qu'est un groupe



k-means cherche des groupes ronds autour d'un centre et attribue chaque point à l'un d'eux. DBSCAN cherche des zones denses, trouve des formes allongées, et surtout il sait dire **ce point n'appartient à rien** : c'est la catégorie que k-means n'a pas.

Et une troisième définition : le clustering hiérarchique



Au lieu de fixer k à l'avance, on fusionne à chaque étape les deux groupes les plus proches, et on garde la trace de l'ordre des fusions. Le dendrogramme se coupe ensuite à la hauteur que l'on veut : le nombre de groupes devient une décision que l'on prend en regardant, et non un paramètre à deviner.

Sur nos séjours : aucun k ne ressort

99 343 séjours, 8 colonnes numériques mises à l'échelle.

k	inertie	silhouette	ARI contre la réadmission
2	668 081	0,2023	0,0184
3	600 432	0,1964	0,0380
4	541 600	0,1600	0,0137
6	461 130	0,1758	0,0083
8	398 380	0,1738	0,0072

Ce que l'on croit, ce que la mesure dit

ON CROIT

L'algorithme a rendu trois groupes, donc il y a trois groupes.

LA MESURE DIT

En nommant au mieux les deux clusters trouvés, on obtient **0,6272** d'accuracy contre la réadmission. Répondre systématiquement « non » en donne **0,8861**.

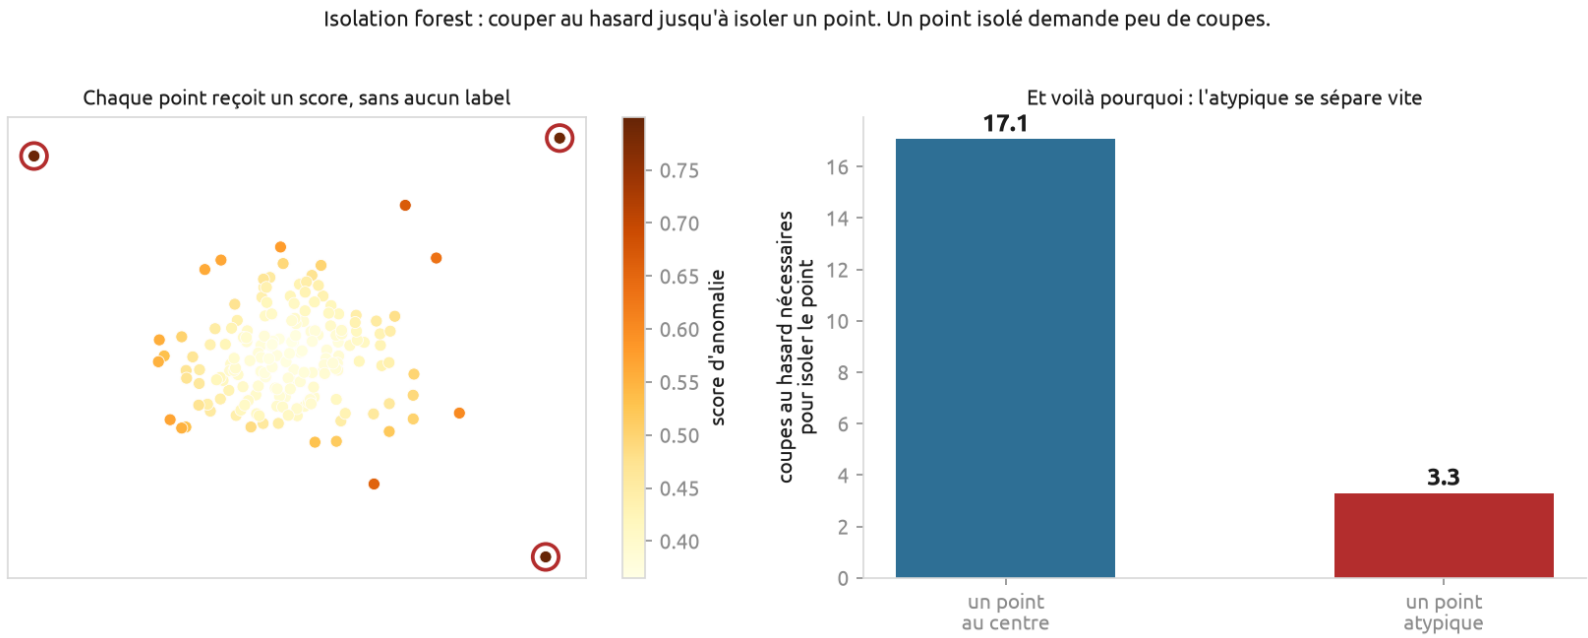
LA BONNE VERSION

Pour **prédire la réadmission à partir de ces huit colonnes**, le clustering fait **26 points de moins** que de ne rien faire. Les groupes existent, ils ne séparent pas ce qui nous intéresse ici, et rien dans la sortie de l'algorithme ne vous l'aurait dit. Ce n'est pas un verdict sur le clustering : le ranking d'anomalies, dans dix minutes, marchera sur les mêmes colonnes.

Un événement rare n'est pas un cluster.

11,4 % de réadmissions réparties dans toute la population ne forment pas un groupe compact dans l'espace des features. Chercher un cluster quand on veut détecter un événement rare est une erreur de méthode, pas de réglage.

Isolation forest : pourquoi l'atypique se repère vite



On coupe l'espace au hasard, encore et encore, jusqu'a isoler chaque point. A droite, la mesure : il faut 17,1 coupes en moyenne pour isoler un point du centre, et 3,3 pour un point atypique. C'est tout l'algorithme, et le score d'anomalie n'est rien d'autre que ce nombre de coupes.

Et maintenant ce qui marche, sans aucun label

IsolationForest, contamination automatique, aucune target lue.

méthode	labels nécessaires	rendement sur 200
supervised, bloc C	99 343 séjours annotés	42,5 %
anomaly detection	aucun	38,5 %
au hasard	aucun	11,4 %

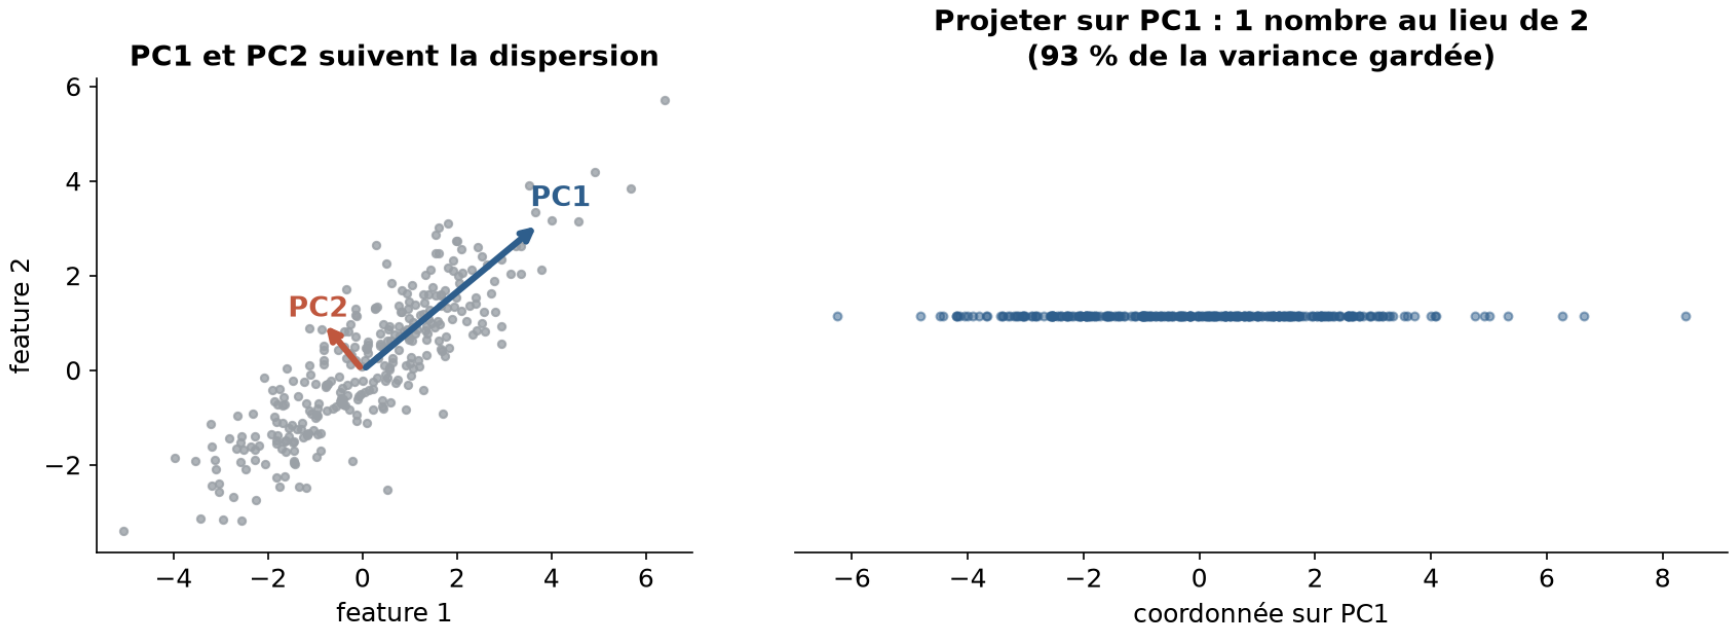
91 % du rendement, zéro annotation

38,5 % contre 42,5 %

Le rendement sur 200 patients, sans labels puis avec.

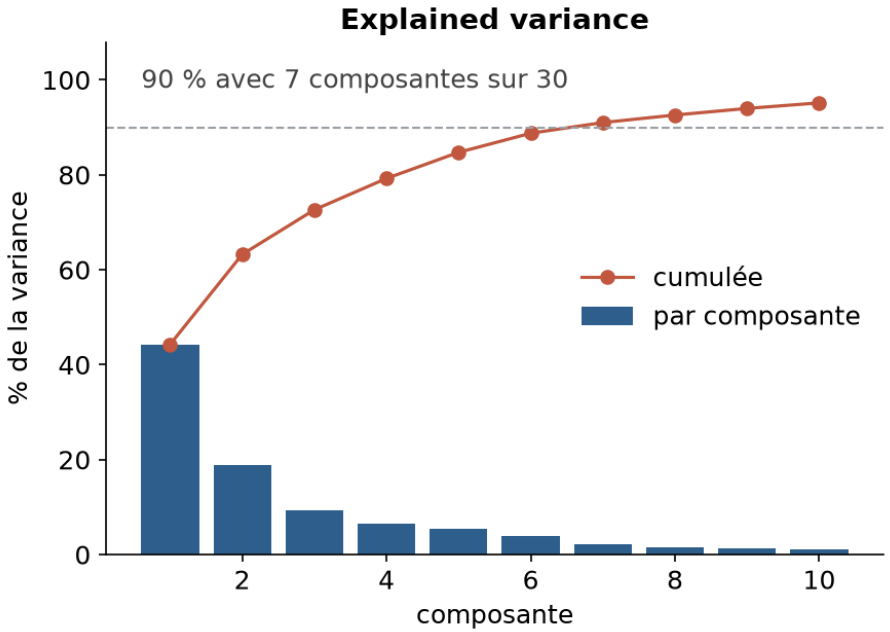
Avant de financer six mois d'annotation, mesurez ce que donne la version sans label. Cela prend trois lignes, et cela a déjà décidé de la suite de plus d'un projet.

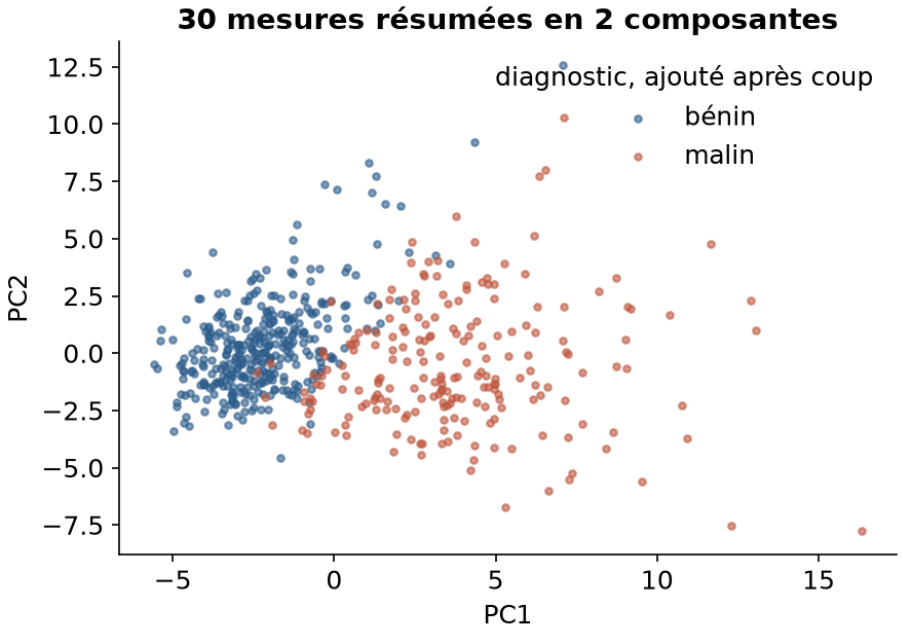
La PCA est une rotation, avant d'être une compression



On ne jette rien au premier temps : on cherche les directions selon lesquelles les données varient le plus, et on redécrit les mêmes points dans ces directions. La perte n'arrive qu'au second temps, quand on décide de ne garder que les premières.

Et la courbe qui dit combien en garder





La variance cumulée en fonction du nombre de composantes gardées. Un coude net signifie que peu de composantes suffisent. Sur nos huit colonnes de séjours, il n'y a pas de coude : il en faut sept sur huit pour atteindre 90 %.

Et la PCA ne comprime presque rien ici

Il faut sept composantes sur huit pour atteindre 90 %.

composantes gardées	variance expliquée
2	42,5 %
3	54,8 %
4	66,7 %
6	86,1 %
7 sur 8	90,0 %

Ce que le bloc F a établi, et ce qui conclut la journée

Sans target, plus rien ne se vérifie tout seul il faut aller chercher un point de comparaison extérieur.

Un algorithme qui rend des groupes n'a pas trouvé de groupes 0,6272 contre 0,8861 : ici il dégrade.

Un événement rare n'est pas un cluster 11,4 % répartis partout ne forment pas une région.

Le sans-label peut suffire 38,5 % contre 42,5 %, et aucune annotation.

Demain tout cela sur notebook, en binôme, et c'est vous qui tapez.