DATA SCIENCE, MACHINE LEARNING, DEEP LEARNING ET NLP

Parcours IAS · Centrale Lille

Projet portfolio

De la donnée de santé brute à une aide à la décision

Un projet personnel, de bout en bout, qui reprend les trois journées du cours et qui vous servira de portfolio.

À réaliser seul, sur votre temps libre.
Une dizaine de semaines, environ quatre heures par semaine.
À terminer avant de candidater.

Sommaire

1 Pourquoi ce projet
2 Le principe : un problème, trois volets
3 Les règles
4 Choisir son sujet : quatre pistes et une libre
5 Le déroulé, en onze étapes
6 Le dépôt et son README
7 La grille d'auto-évaluation
8 Les pièges que le cours vous a appris à voir
9 Un calendrier possible
10 En entretien

Édition 2026-2027. Les données citées ont été vérifiées sur data.gouv.fr en octobre 2026.

1. Pourquoi ce projet

Dans six mois vous serez sur le marché de l'emploi. Votre diplôme dira que vous avez suivi un cours de data science. **Un projet montrera que vous savez faire le métier**, et c'est ce que l'on vous demandera en entretien.

Ce qui vous distinguera n'est pas un score de 0,99 sur un jeu de données d'école. Des milliers de candidats en ont un, et un recruteur technique sait qu'il ne prouve rien. Ce qui vous distinguera, c'est un projet où l'on voit que vous avez **cherché la fuite avant de célébrer le score**, comparé votre modèle à un baseline honnête, et traduit une métrique en décision. C'est exactement ce que les trois journées vous ont appris, et presque personne ne le montre.

Ce sujet vous donne une structure, des données dont la licence a été vérifiée, et une grille pour juger vous-même votre travail. Il ne vous donne pas la réponse : personne ne la connaît, et c'est ce qui fait sa valeur.

> **Ce que ce projet n'est pas.** Ni un concours de score, ni un travail de groupe, ni un dispositif médical. Il se fait **seul**, sur votre temps libre, en une dizaine de semaines à raison de quatre heures par semaine environ. Il vous appartient : c'est votre dépôt, à votre nom.

2. Le principe : un problème, trois volets

Vous choisissez **un acteur de santé** et **une décision** qu'il doit prendre. Tout le projet sert cette décision. Il se construit en trois volets, qui reprennent les trois journées dans l'ordre.

volet	ce que vous construisez	ce qu'il démontre	journées
A. Prédire et décider	un modèle sur des données tabulaires et temporelles, et une liste d'actions sous contrainte de budget	cadrage, nettoyage, fuites, baselines, métriques, seuil, réseau de neurones, séries temporelles, non supervisé	1 et 2
B. Lire et interroger	un classifieur de texte, puis un assistant RAG sur les documents officiels de votre domaine	représentation du texte, score trop beau, retrieval mesurée, refus motivé	3
C. Rendre compte	un dépôt propre, un README, une note de décision de deux pages, un pitch de trois minutes	la capacité à expliquer un résultat à quelqu'un qui n'a pas le temps	les trois

3. Les règles, et elles ne se négocient pas

règle	pourquoi
Données ouvertes uniquement, et la licence est lue sur la fiche du jeu de données puis recopiée dans votre README.	Votre dépôt sera public. Le cours a écarté un jeu de données réputé libre parce qu'il ne l'était pas. Sur data.gouv.fr, Open Medic est en Licence Ouverte, mais Open Bio et Open LPP, du même éditeur, affichent une licence non spécifiée : on ne devine pas, on vérifie.
Aucune donnée personnelle de santé. Des données agrégées, et aucune tentative de ré-identification.	Les données de santé sont des données sensibles au sens du RGPD. Un recruteur en santé regardera ce point avant tout autre.

règle	pourquoi
Chaque chiffre du README sort d'une exécution de votre code, graine fixée, sortie brute conservée dans le dépôt.	C'est la règle du cours : rien n'arrive sur une diapositive avant d'avoir été mesuré. Un chiffre recopié de mémoire finit toujours faux.
Reproductible en une commande, versions épinglées, version de Python écrite.	Si un inconnu ne peut pas rejouer votre projet, il ne peut pas le croire.
L'assistant dit ce qu'il est : une démonstration d'ingénierie, pas un conseil médical. Et il refuse hors de son corpus.	Un système qui répond à une question de santé sans source est dangereux, pas seulement faux.
Les assistants de code sont autorisés (ChatGPT, Claude, Copilot), à deux conditions : vous pouvez expliquer chaque ligne, et vous le dites dans le README.	En entretien on vous demandera pourquoi cette ligne est là. « L'IA l'a écrite » n'est pas une réponse, et le cacher se voit.

4. Choisir son sujet

Quatre pistes, toutes vérifiées : les données existent, elles sont téléchargeables, et leur licence permet un dépôt public. Une cinquième est libre. **Deux étudiants de la promotion sur la même piste, c'est normal. Deux fois la même question, non** : choisissez une région, une classe de médicaments, une pathologie ou un acteur qui soit le vôtre. C'est ce qui rendra votre projet reconnaissable parmi ceux de vos camarades.

Piste 1 : les médicaments et la dépense publique	
acteur	l'Assurance Maladie, ou une agence régionale de santé.
la décision	quelles classes de médicaments verront leur dépense augmenter l'an prochain, et quelle part de la dépense va à des médicaments dont le service médical rendu est jugé insuffisant ?
données	**Open Medic**, Assurance Maladie, bases annuelles de 2014 à 2025, par classe ATC, âge, sexe, région et prescripteur, Licence Ouverte. **Base de données publique des médicaments**, fichiers `CIS`, `CIS_CIP`, `CIS_HAS_SMR` et `CIS_HAS_ASMR`, Licence Ouverte.
volet A	prévoir la hausse de dépense d'une classe ATC, découpage par année ; classer les classes par risque sous un budget de contrôles.
volet B	classer les avis de la Commission de la transparence par niveau d'**ASMR**, et non de SMR comme au TD 7 ; un assistant qui répond sur l'ASMR d'un médicament et refuse hors corpus.
le piège à chercher	trois identifiants, `CIP13`, `CIS` et code ATC : lequel est la maille ? Lisez aussi la note de l'éditeur, qui signale une anomalie sur les données 2025, corrigée en juillet 2026.

Piste 2 : la tension aux urgences

acteur	une agence régionale de santé.
la décision	peut-on prévoir la tension de la semaine prochaine, et pour quels départements la prévision vaut-elle la peine d'être faite ?
données	**Santé publique France**, passages aux urgences et actes SOS Médecins, quotidiens, par département et tranche d'âge, Licence Ouverte 2.0. Population par département, INSEE : licence à vérifier vous-même. Pour le volet B, les articles de Wikipédia en français sur les pathologies saisonnières, sous CC BY-SA 4.0, donc attribution et partage à l'identique.
volet A	le coeur est temporel : horizon écrit, backtest en plis, naïf saisonnier ; puis classer les départements par profil saisonnier.
volet B	classer des passages de texte par pathologie ; un assistant documentaire sur les pathologies saisonnières, avec refus hors corpus.
le piège à chercher	la série commence en 2020, en pleine épidémie : qu'est-ce qu'une saison normale ? Et quel horizon déclarez-vous, sachant qu'au cours le même code faisait +27,3 % sur un indicateur et -42,8 % sur l'autre ?

Piste 3 : la qualité des soins à l'hôpital

acteur	la Haute Autorité de santé, ou une agence régionale de santé.
la décision	quels établissements faut-il auditer en priorité, et la certification dit-elle la même chose que la satisfaction des patients ?
données	**e-Satis**, HAS, plusieurs recueils annuels, Licence Ouverte. **Certification des établissements de santé**, 6e cycle, HAS, Licence Ouverte 2.0, mise à jour en octobre 2026. Pour le volet B, les documents méthodologiques publiés avec ces jeux, comme `modalites-calculs-esatis48hmco.pdf`, sous la même licence.
volet A	prolonger le projet du jour 2 sur plusieurs années et ajouter les résultats de certification ; une typologie des établissements sans label.
volet B	un assistant qui répond aux questions de méthodologie : comment le score est-il ajusté, que veut dire DI ? Et qui refuse ce que les documents ne disent pas.
le piège à chercher	vous l'avez vu : `finess` est l'entité juridique, et l'AP-HP porte 21 sites sous un seul. Le lexique donne les seuils du classement, qui se retrouve 99,34 % du temps à partir du score. Et les années de certification ne sont pas celles d'e-Satis.

Piste 4 : l'accès aux soins dans les territoires	
acteur	une agence régionale de santé, ou une collectivité.
la décision	quelles communes risquent de basculer en zone sous-dense, et quels territoires se ressemblent assez pour partager une politique ?
données	**Accessibilité potentielle localisée (APL)**, ministère des Solidarités, à la commune, Licence Ouverte 2.0. Données communales de l'INSEE : licence à vérifier. Pour le volet B, la documentation méthodologique publiée avec les jeux APL, après vérification de sa licence.
volet A	classer les communes par risque de bascule, avec un découpage qui respecte le temps ; une typologie non supervisée des territoires.
volet B	un assistant documentaire sur la méthode de l'APL, qui refuse de répondre sur une commune absente de ses sources.
le piège à chercher	l'APL est calculée à partir de l'offre de médecins : mettre cette offre dans les features, c'est donner la réponse. Et une commune de trente habitants pèse-t-elle comme une ville ?

Piste 5 : libre

Un autre sujet est possible à quatre conditions : des données de santé ouvertes dont vous avez lu la licence, aucune donnée personnelle, une cible que l'on peut prédire, et un corpus de texte pour le volet B. Faites relire votre spécification de l'étape 1 par un camarade avant d'écrire une ligne de modèle.

5. Le déroulé, étape par étape

Onze étapes, de la licence au pitch. Les durées sont indicatives et totalisent environ quarante-cinq heures. Chaque étape reprend un bloc du cours, et se termine par la question qu'un recruteur vous posera : si vous savez y répondre avec votre propre projet, l'étape est faite.

0 Les données, et leur licence

2 h · bloc A · TD 1

- Télécharger les fichiers bruts par un script, jamais à la main, pour que le téléchargement se rejoue.
- Lire la fiche de chaque jeu de données : éditeur, licence, date de mise à jour, notes de l'éditeur.
- Écrire `donnees/LICENCES.md` : un jeu par ligne, sa licence, sa source, et ce que la licence vous oblige à faire.

Ce que vous livrez. le script de téléchargement et `LICENCES.md`.

Vous avez réussi si un inconnu peut retrouver chaque fichier et sa licence sans vous écrire.

> **En entretien :** « D'où viennent vos données, et avez-vous le droit de les publier ? »

1 La spécification

2 h · bloc B · TD 2

- Transformer la demande de l'acteur en cinq éléments : **target, maille, inputs, metric, seuil d'acceptabilité**.
- Écrire pour chaque input s'il **existera au moment de la décision**. C'est la question qui relie tout le cours.
- Écrire la décision que le résultat permettra de prendre, et ce qui se passe si le modèle se trompe dans chaque sens.

Ce que vous livrez. une page, `rapport/specification.md`, écrite avant tout code.

Vous avez réussi si un camarade la lit et sait ce que vous allez prédire, sur quelle ligne, et comment vous jugerez le résultat.

> **En entretien :** « Qu'est-ce que vous prédisez exactement, et pourquoi cette métrique ? »

2 Profiler, nettoyer, chercher la fuite

5 h · bloc B · TD 2

- Compter les manquants sous **toutes leurs formes** : `NaN`, `?`, codes administratifs, valeurs sentinelles.
- Vérifier l'unité d'analyse : une clé qui se répète n'est pas une clé. Au cours, découper par ligne laissait 7 856 patients des deux côtés du split.
- Pour chaque colonne : est-elle connue avant la décision, ou contient-elle déjà la réponse ?

Ce que vous livrez. un tableau « ce que le fichier contient vraiment », et la liste des colonnes écartées avec leur raison.

Vous avez réussi si vous pouvez nommer au moins une fuite que vous avez évitée, et la prouver par une mesure.

> **En entretien :** « Comment savez-vous que votre modèle ne triche pas ? »

3 Les baselines d'abord

2 h · bloc C · TD 3

- Le taux de base, et ce que donne « répondre toujours la classe majoritaire ».
- Un baseline métier : ce que l'acteur fait aujourd'hui sans modèle, par exemple reconduire le résultat de l'an dernier.
- Une règle écrite à la main, si une règle simple existe.

Ce que vous livrez. un tableau de baselines, avant le premier modèle.

Vous avez réussi si vous savez quel chiffre votre modèle doit battre, et pourquoi celui-là.

> **En entretien :** « Votre modèle bat quoi, exactement ? »

4 Le modèle, ses métriques, et la décision

6 h · bloc C · TD 3

- Un découpage qui respecte la structure : groupé si une entité revient, temporel si les lignes ont un ordre.
- La matrice de confusion, la courbe ROC et l'AUC, et pas l'accuracy seule : au cours, une accuracy de 0,8862 cachait un recall de 0,78 %.
- Le seuil comme décision : coût de chaque erreur écrit comme une hypothèse, puis le rendement sous un budget réaliste.

Ce que vous livrez. la liste des actions recommandées sous budget, avec son rendement contre le hasard et contre le baseline métier.

Vous avez réussi si votre livrable principal est une liste et son rendement, et non un score.

> **En entretien :** « Que vaut votre modèle pour quelqu'un qui doit décider demain ? »

5 Le réseau de neurones a-t-il payé ?

4 h · bloc D · TD 4

- Un réseau en PyTorch, avec la boucle écrite à la main : zero_grad, forward, loss, backward, step.
- Comparer au meilleur modèle de l'étape 4 sur l'AUC, le bénéfice, le temps, la taille et le nombre de réglages.
- Tracer les courbes de loss et dire ce qu'elles montrent.

Ce que vous livrez. un tableau de comparaison, et une conclusion qui peut être « non ».

Vous avez réussi si vous pouvez justifier le modèle retenu par des chiffres, même si ce n'est pas le réseau.

> **En entretien :** « Pourquoi n'avez-vous pas utilisé de deep learning ? »

6 Le temps

5 h · bloc E · TD 5

- Écrire l'**horizon** de prévision avant toute feature : il décide lesquelles existent.
- Un backtest en plusieurs plis, chacun entraîné sur ce qui précède.
- Le naïf saisonnier comme adversaire, et l'écart entre le meilleur et le pire pli à côté de la moyenne.

Ce que vous livrez. une figure du backtest, et un tableau naïfs contre modèle.

Vous avez réussi si vous pouvez dire à quel horizon votre prévision vaut quelque chose, et à quel horizon elle ne vaut plus rien.

> **En entretien :** « Comment avez-vous validé une prévision sans voir le futur ? »

7 Sans la cible

3 h · bloc F · TD 6

- Un clustering, confronté à quelque chose d'extérieur : un algorithme rend toujours des groupes.
- Un ranking d'anomalies, mesuré contre la cible mise de côté.
- Une PCA, et ce qu'elle dit de la redondance de vos colonnes.

Ce que vous livrez. un paragraphe qui dit ce que la structure sans label apporte, ou n'apporte pas.

Vous avez réussi si vous savez dire si vos groupes servent à quelque chose, chiffre à l'appui.

> **En entretien :** « Vos clusters veulent-ils dire quelque chose ? »

8 Le texte

4 h · jour 3 · TD 7

- Une représentation simple d'abord, TF-IDF, et une règle écrite à la main comme adversaire.
- Si le score est trop beau, chercher pourquoi : le label est-il écrit dans le texte ? Masquer, puis remesurer.
- Le rapport par classe, et pas seulement la moyenne.

Ce que vous livrez. un tableau avant et après masquage, et le rapport par classe.

Vous avez réussi si vous savez ce que votre classifieur a vraiment appris.

> **En entretien :** « Votre score de 99 %, il vient d'où ? »

9 L'assistant

6 h · jour 3 · TD 8 et TD 9

- Découper le corpus, encoder, retrouver : mesurer la **retrieval seule**, avec un hit@k sur des questions dont vous connaissez la réponse.
- Comparer au moins deux façons de chercher, sur vos vraies questions : au TD 9, sur un nom de médicament, le TF-IDF trouvait le bon avis en tête 36 fois sur 40, l'encodeur dense 6 fois.
- Une interface Gradio **locale**, qui affiche ses sources et tient un journal des refus : le TD 9 en donne le squelette.
- Générer avec le contexte, et une consigne de refus explicite.
- Tester sur des questions **sans réponse** dans le corpus, et sans retrieval : au cours, le modèle seul inventait 3 réponses sur 3.

Ce que vous livrez. un tableau hit@k, réponses justes, refus corrects, inventions.

Vous avez réussi si vous savez où se trouve le goulot de votre système : au cours, le hit@3 valait 6 sur 9, exactement le nombre de réponses justes.

> **En entretien :** « Votre assistant hallucine-t-il, et comment le savez-vous ? »

10 La restitution

5 h · tout le cours

- Le README, sur le modèle de la section 6.
- Une note de décision de deux pages pour l'acteur, sans code, avec la liste, son rendement et ses limites.
- Un pitch de trois minutes, enregistré si vous le pouvez.

Ce que vous livrez. le dépôt public, propre, qui se rejoue en une commande.

Vous avez réussi si quelqu'un qui ne connaît pas le sujet comprend votre résultat en lisant le seul README.

> **En entretien :** « Présentez-moi votre projet en trois minutes. »

6. Le dépôt et son README

Un recruteur ou un manager technique lit d'abord le README, puis regarde une figure, puis le code s'il lui reste du temps. **Écrivez pour ce lecteur pressé.** La structure ci-dessous est un point de départ, pas une obligation.

```
mon-projet/
  README.md                 ce que l'on lit en premier
  requirements.txt          versions epinglees, Python ecrit en tete
  telecharger.py            recupere les donnees brutes
  donnees/LICENCES.md       une licence par jeu de donnees
  src/                      le code reutilisable
  notebooks/                un notebook par volet, executes
  resultats/mesures.txt     la sortie brute : votre registre
  rapport/specification.md  l'etape 1
  rapport/note_decision.pdf deux pages, pour l'acteur
```

Le README, dans cet ordre :

section	ce qu'elle contient
La question	l'acteur et sa décision, en une phrase.
Le résultat	une phrase avec un chiffre **et son point de comparaison** : « trouve 3,4 fois plus de cas que le hasard dans un budget de 20 », jamais « AUC de 0,84 » seul.
Une figure	celle qui porte la décision, lisible sans légende orale.
Les données	sources, licences, ce que vous avez écarté et pourquoi.
Ce que j'ai trouvé en route	la fuite, le piège, le résultat négatif. C'est la section que l'on retient.
Reproduire	trois commandes au plus.
Limites	trois, écrites avant que quelqu'un ne les trouve.
Usage des assistants IA	une phrase honnête.
La suite	ce que vous feriez avec un mois de plus.

7. La grille d'auto-évaluation

Cochez avant de publier. Une case vide n'est pas une faute : c'est une limite à écrire dans le README.

Données et cadrage

- ☐ Chaque jeu de données a sa licence, lue sur sa fiche et recopiée.
- ☐ Aucune donnée personnelle ; données agrégées seulement.
- ☐ La spécification en cinq éléments existe et précède le code.
- ☐ L'unité d'analyse est écrite, et la clé de jointure vérifiée.
- ☐ Au moins une fuite a été cherchée, nommée, et écartée par une mesure.

Modélisation et évaluation

- ☐ Le taux de base et un baseline métier sont dans le README.
- ☐ Le découpage respecte les groupes et le temps.
- ☐ L'accuracy n'apparaît jamais seule : matrice de confusion et AUC à côté.
- ☐ Le seuil est présenté comme une décision, avec ses hypothèses de coût.
- ☐ Le livrable est un rendement sous budget, comparé au hasard et au baseline.
- ☐ Le réseau de neurones est comparé, et la conclusion est assumée.
- ☐ L'horizon de prévision est écrit, et le backtest a plusieurs plis.
- ☐ Le résultat non supervisé est confronté à quelque chose d'extérieur.

Texte et assistant

- ☐ Le classifieur de texte est comparé à une règle écrite à la main.
- ☐ Un score trop beau a été expliqué, masquage à l'appui.
- ☐ La retrieval est mesurée seule, par un hit@k.
- ☐ L'assistant refuse hors corpus, et c'est testé sur des questions inventées.

Restitution

- ☐ Chaque chiffre du README se retrouve dans `resultats/mesures.txt`.
- ☐ Le projet se rejoue en une commande, versions épinglées.
- ☐ Le README se comprend sans ouvrir le code.
- ☐ Trois limites sont écrites.
- ☐ Vous pouvez tenir trois minutes sans support.

8. Les pièges que le cours vous a appris à voir

Chacun a été mesuré pendant les trois journées. Si votre projet en évite un et le dit, il dit aussi que vous avez suivi le cours.

le piège	ce que le cours a mesuré
L'accuracy seule	une accuracy de 0,8862 pour un recall de 0,78 % : le système ratait presque toutes les réadmissions.
L'unité d'analyse	un séjour n'est pas un patient : le découpage par ligne offrait +0,0052 d'AUC que le modèle n'avait pas gagnés.
La clé qui n'en est pas une	l'AP-HP, 21 sites sous un seul `finess` : une jointure naïve fabrique un produit cartésien, en silence.
La cible déjà dans les colonnes	le lexique e-Satis donne les seuils, et la règle retrouve le classement 99,34 % du temps.
L'horizon non écrit	`lag_1` est légitime à un jour, et une fuite à sept. Même code, deux conclusions.
Le signal qui ne se prévoit pas	le même pipeline gagnait +27,3 % sur un indicateur, et -42,8 % sur un autre.
Le seuil de 0,50	une valeur par défaut que personne n'a choisie, et presque jamais la bonne.
La retrieval non mesurée	un hit@3 de 6 sur 9 et exactement autant de réponses justes : le goulot n'était pas le générateur.
Le modèle qui n'a pas le droit de refuser	sans contexte, 3 inventions sur 3 médicaments qui n'existent pas.

9. Un calendrier possible

semaine	étapes	ce qui doit exister à la fin
1	0 et 1	les données, leurs licences, la spécification
2	2	le profilage, et la fuite trouvée ou écartée
3	3 et début de 4	les baselines, un premier modèle
4	fin de 4	la liste sous budget et son rendement
5	5	la comparaison avec le réseau de neurones
6	6	le backtest et son horizon
7	7 et début de 8	la structure sans label, le corpus de texte
8	fin de 8	le classifieur, avant et après masquage
9	9	l'assistant et son tableau d'évaluation
10	10	le README, la note de décision, le pitch

Terminez avant de candidater. Un projet à moitié fait se voit plus qu'un projet plus modeste mais fini. Si le temps manque, réduisez la profondeur des étapes 5 et 7, jamais celle des étapes 2, 4 et 10.

10. En entretien

Le pitch tient en trois phrases. Remplissez-les avec votre projet, et vous aurez la réponse à « parlez-moi d'un projet ».

> « J'ai aidé **[l'acteur]** à décider **[la décision]**. Sur **[les données]**, mon modèle trouve **[X] fois plus de [cas]** que le hasard dans un budget de **[N]**, là où l'accuracy aurait fait croire **[ce qu'elle aurait fait croire]**. En route, j'ai trouvé **[la fuite ou le piège]**, qui gonflait le score de **[combien]**. »

Les questions qui viendront, et où se trouve la réponse

la question	la réponse est à
Pourquoi ce modèle et pas un autre ?	l'étape 5 : le tableau de comparaison, y compris si le réseau perd.
Comment savez-vous qu'il n'y a pas de fuite ?	l'étape 2 : la fuite que vous avez trouvée, et sa mesure.
Votre score, comparé à quoi ?	les étapes 3 et 4 : le baseline métier et le rendement sous budget.
Votre assistant invente-t-il ?	l'étape 9 : les questions sans réponse, et les refus comptés.
Qu'est-ce qui n'a pas marché ?	la section « ce que j'ai trouvé en route » de votre README. Un résultat négatif bien mesuré est une force, pas un aveu.
Que feriez-vous avec plus de temps ?	la dernière section du README.

Un dernier conseil. La question la plus fréquente en entretien technique n'est pas « quel est votre score », c'est « comment le savez-vous ». Tout ce projet est construit pour que vous puissiez y répondre.